**دانشگاه صنعتی شریف**

دانشکده مهندسی کامپیوتر

# بازشناسی مقاوم گفتار در زبان فارسی

**پویا فلاح سیچانی**

استاد راهنما: دکتر حسین صامتی

دفاع پایان‌نامه کارشناسی ارشد

# شکاف میان گفتار آموزشی و تماس واقعی

## گفتار در دسترس

پیکره‌های عمومیِ فارسی
قطعه‌های عمدتاً کوتاه
سبک‌ها و شرایط ضبط متنوع

## شرایط تماس

نویز و پهنای‌باند محدود
اعوجاج کدک و افت بسته
تلفن و تماس اینترنتی

## هدف: کاهش خطای تماس واقعی با داده‌های موجود

گردآوری تماس رونویسی‌شده پرهزینه و حساس به حریم خصوصی است

# آموزش، سازگارسازی و اصلاح خروجی

| خانواده روش | ایده اصلی | نمونه پژوهش‌ها |
|---|---|---|
| **آموزش چندشرایطی و داده‌افزایی** | آموزش با نویز و تخریب کانال، همراه با تنوع آکوستیکی هدفمند | pMCT (2022)<br>Acoustic-aware Aug. (2025*) |
| **انطباق مدل‌های پایه** | ریزتنظیم کامل یا کم‌پارامتر، با داده متناسب با زبان و دامنه | MCAT–LoRA (2025) / SPS (2026)<br>Neyshekar (2026*) |
| **یادگیری خودنظارتی و نیمه‌نظارتی** | پیش‌آموزش با صوت بی‌برچسب، خودتقطیر و پالایش شبه‌برچسب‌ها | Bhogale et al. (2024)<br>Cross-lingual (2025) / DASH (2026) |
| **اصلاح با مدل زبانی** | اصلاح فرضیه‌های بازشناس با مدل زبانی و شواهد صوتی | ClozeGER / Listen Again (2024)<br>Conservative Filtering (2024) |

**ارزیابی‌های جدید**

Speech Robust Bench (2025)  URGENT (2025)  PSRB (2025*)

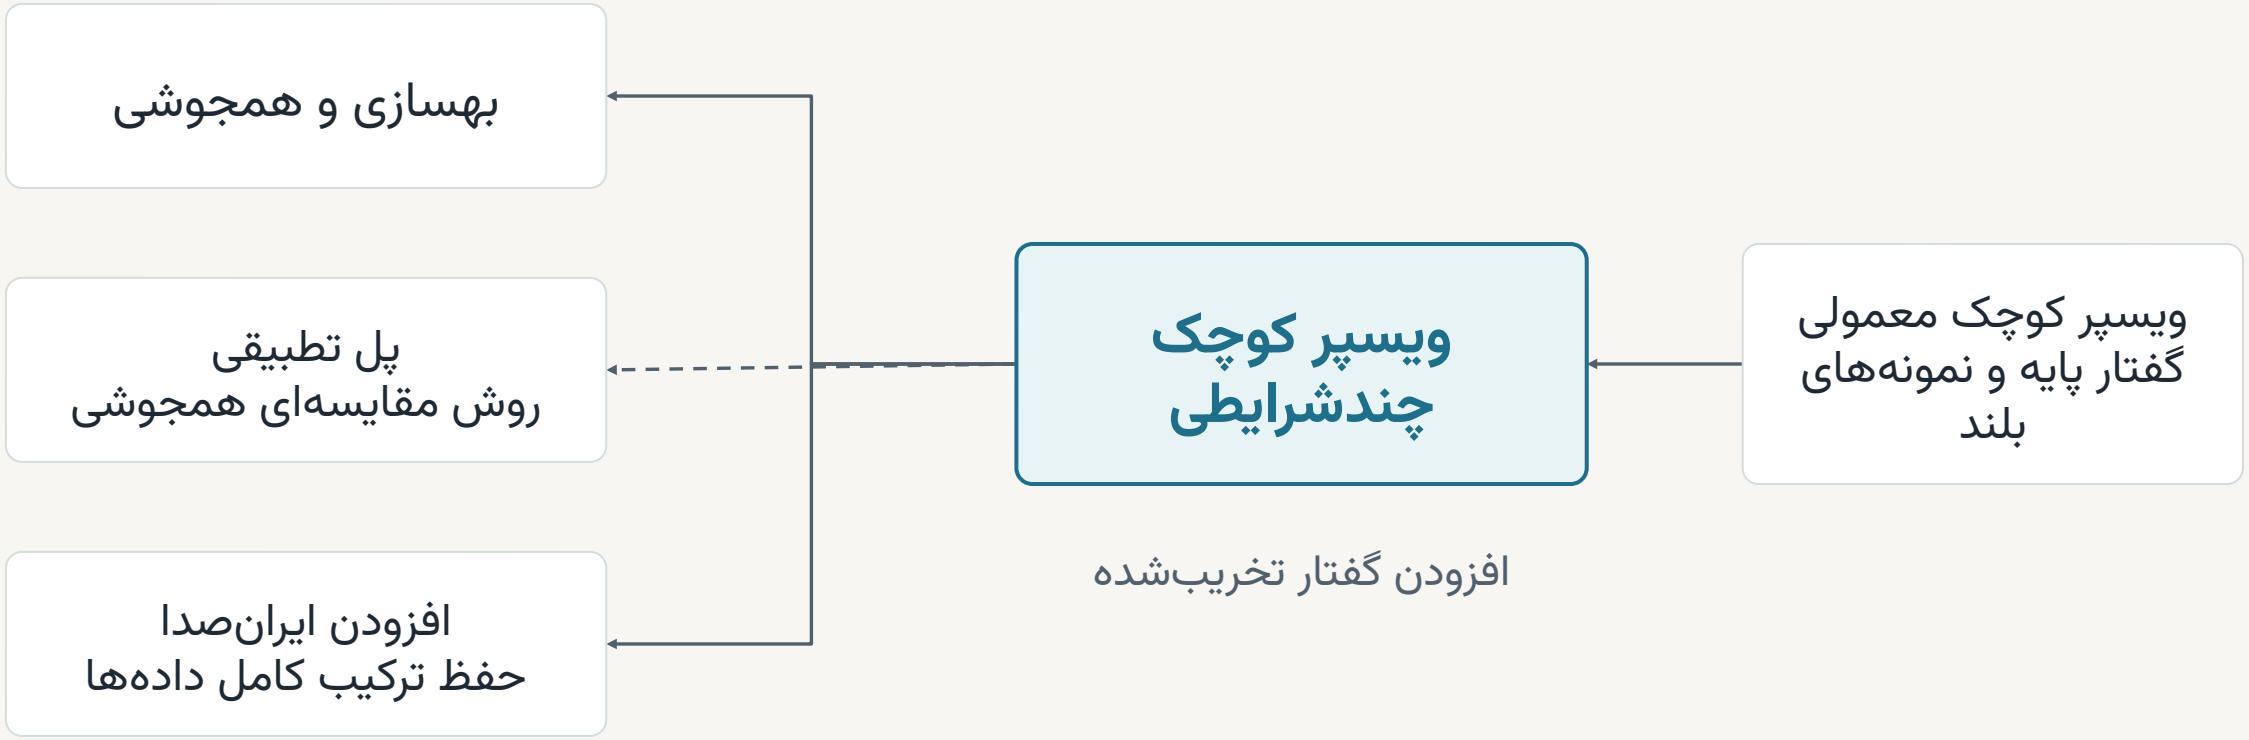
ستاره: پیش‌چاپ، با وضعیت انتشار بررسی‌شده تا ۱۵ اکتبر ۲۰۲۶

# بهسازی گفتار و ادغام نماها

| خانواده روش | ایده اصلی | نمونه پژوهش‌ها |
|---|---|---|
| **بهسازی پیش از بازشناسی** | بازسازی گفتار با بهساز پیش‌بینی‌گر یا مولد پیش از بازشناسی | Schrödinger Bridge (2025)<br>Decoupled SE–ASR (2026) |
| **بهسازی وظیفه‌محور** | آموزش بهساز با زیان بازشناسی یا بازنمایی‌های خودنظارتی | Dissen et al. (2025)<br>SSL-MSE / Sato et al. (2025) |
| **همجوشی در فضای بازنمایی** | تعامل و ترکیب ویژگی‌های نمای اصلی و بهسازی‌شده | FAT-HuBERT (2023)<br>Wav2code (2024) |
| **ترکیب در سطح موج** | آمیختن تطبیقی دو موج با پل، اطمینان بازشناس یا پالایش قطعه‌ای | Adaptive Bridge (2024, 2025)<br>Conf-OA / Rethink-and-Refine (2026) |

افزایش کیفیت شنیداری الزاماً به کاهش خطای بازشناسی منجر نمی‌شود

# ساختار آزمایش‌ها و خط مبنا




همجوشی و ایران‌صدا دو مسیر مستقل‌اند. سامانه ترکیبی آن‌ها ارزیابی نشده است

# داده‌های آموزش

## گفتار پایه فارسی

Common Voice Persian 25
FarsSpon (زیرمجموعه محدود)
FLEURS Persian

صوت تک‌کاناله ۱۶ کیلوهرتزی و نرمال‌سازی مشترک متن فارسی

**۲ تا ۴**

**قطعه برای ساخت هر نمونه بلند**

اتصال درون همان بخش داده
بیش از ۵ و حداکثر ۲۰ ثانیه
حضور در خط مبنای معمولی

# ارزیابی روی تماس واقعی و گفتار عمومی

## ۱۰,۰۴۴

### نمونه تماس واقعی در AGFarsdat

تلفن و تماس اینترنتی
مستقل از آموزش و انتخاب مدل

### آزمون‌های گفتار عمومی

Common Voice Persian 25
FLEURS Persian
PersianSpeech
Persian Speech Corpus

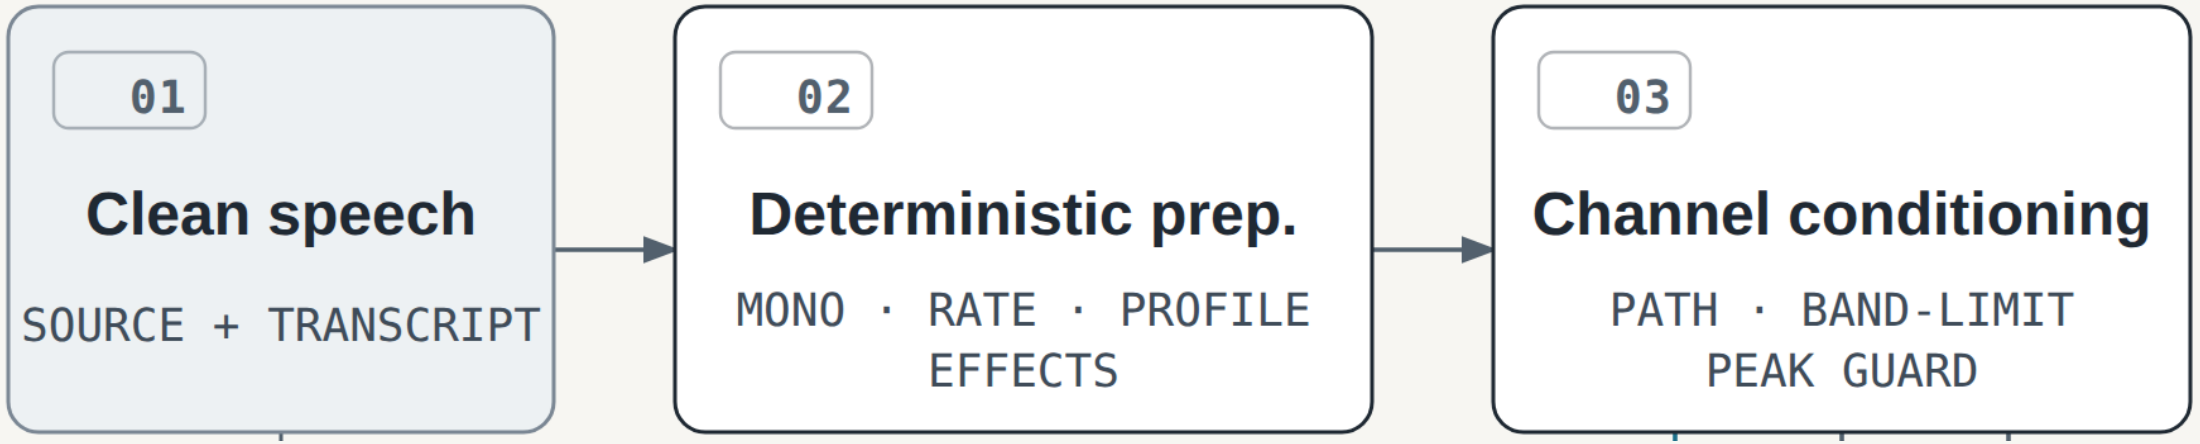
### نرخ خطای واژه

$$WER = (S + D + I) / N$$

CER بر پایه نویسه است. تجمیع با جمع شمارش خطاها و واحدهای مرجع انجام می‌شود
رمزگشایی حریصانه مشترک است. PersianSpeech فقط ۲۴ نمونه دارد و واجدشرایط‌بودن کمی تغییر می‌کند

# داده‌افزایی مخابراتیِ بازتولیدپذیر

ساخت جفت‌های پاک و تخریب‌شده با رونویسی مشترک




## نویز و تغییر بهره

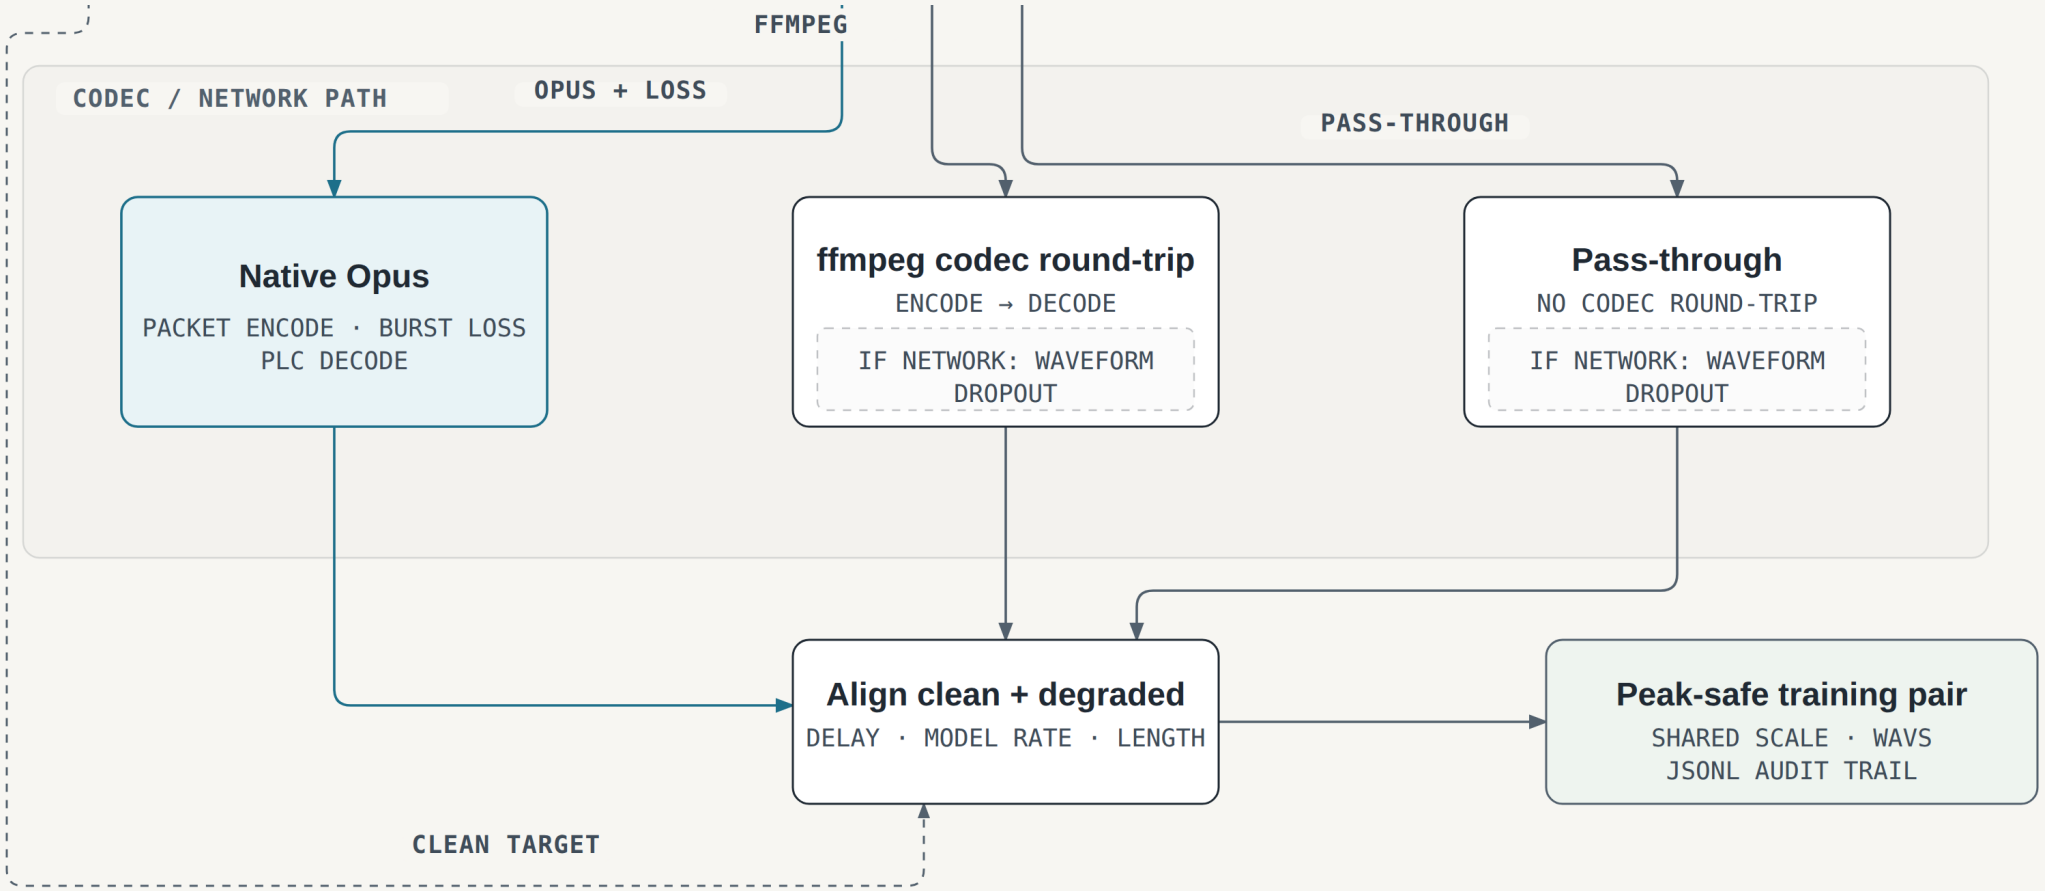
DEMAND  SNR: -5 … 15 dB  Gain: ±6 dB

## نمایه‌های تلفن و تماس اینترنتی

ثبت بذر تصادفی و فراداده هر جفت

وزن نمایه‌ها یک توزیع طراحی‌شده است و از آمار اپراتور به دست نیامده است

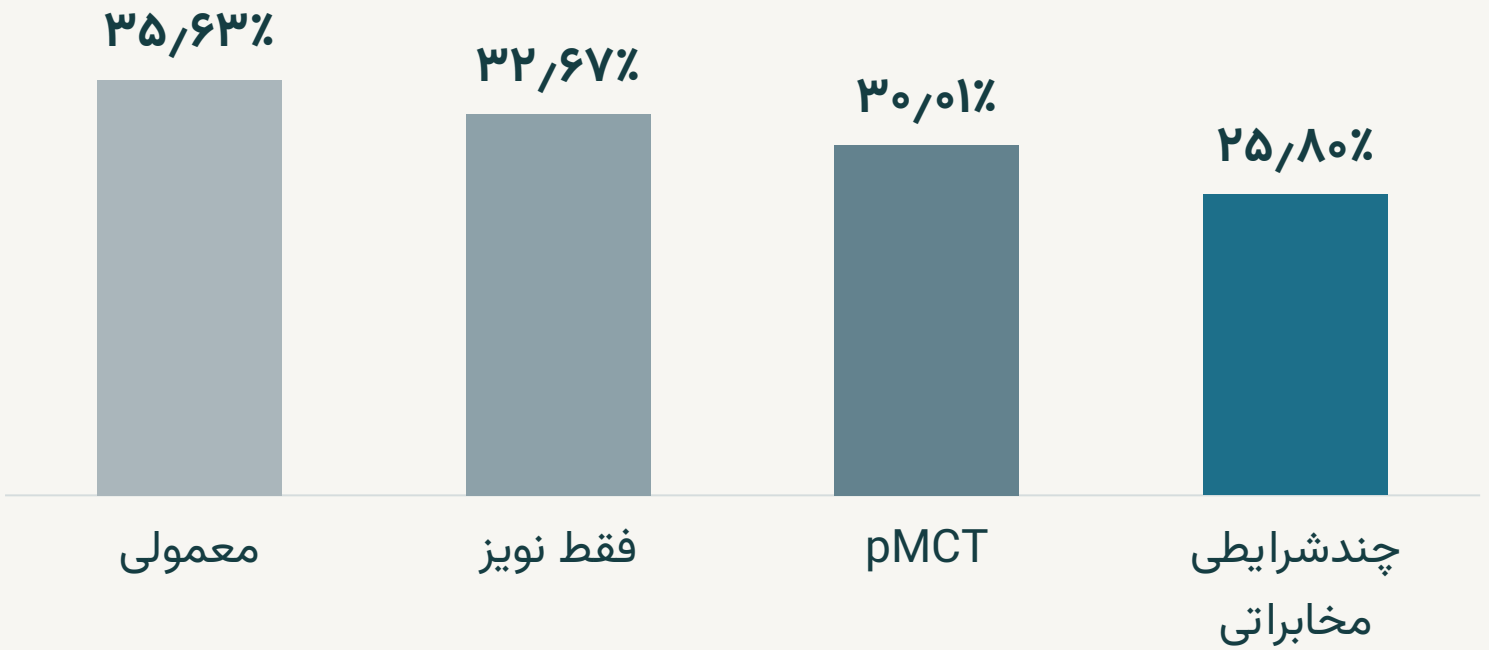
# مسیرهای کدک و جفت‌های هم‌تراز




AMR-WB، AMR-NB، GSM، G.711 و Opus. هدف پاک، پهنای‌باند متناظر با کانال را حفظ می‌کند
Opus بومی افت بسته و پنهان‌سازی خطا را مدل می‌کند. در مسیرهای دیگر، حذف موج یک تقریب است

# انتقال بهبود به تماس‌های واقعی

## نرخ خطای واژه در AGFarsdat




**۹٫۸۳**

**واحد درصد کاهش خطا در تماس‌های واقعی**

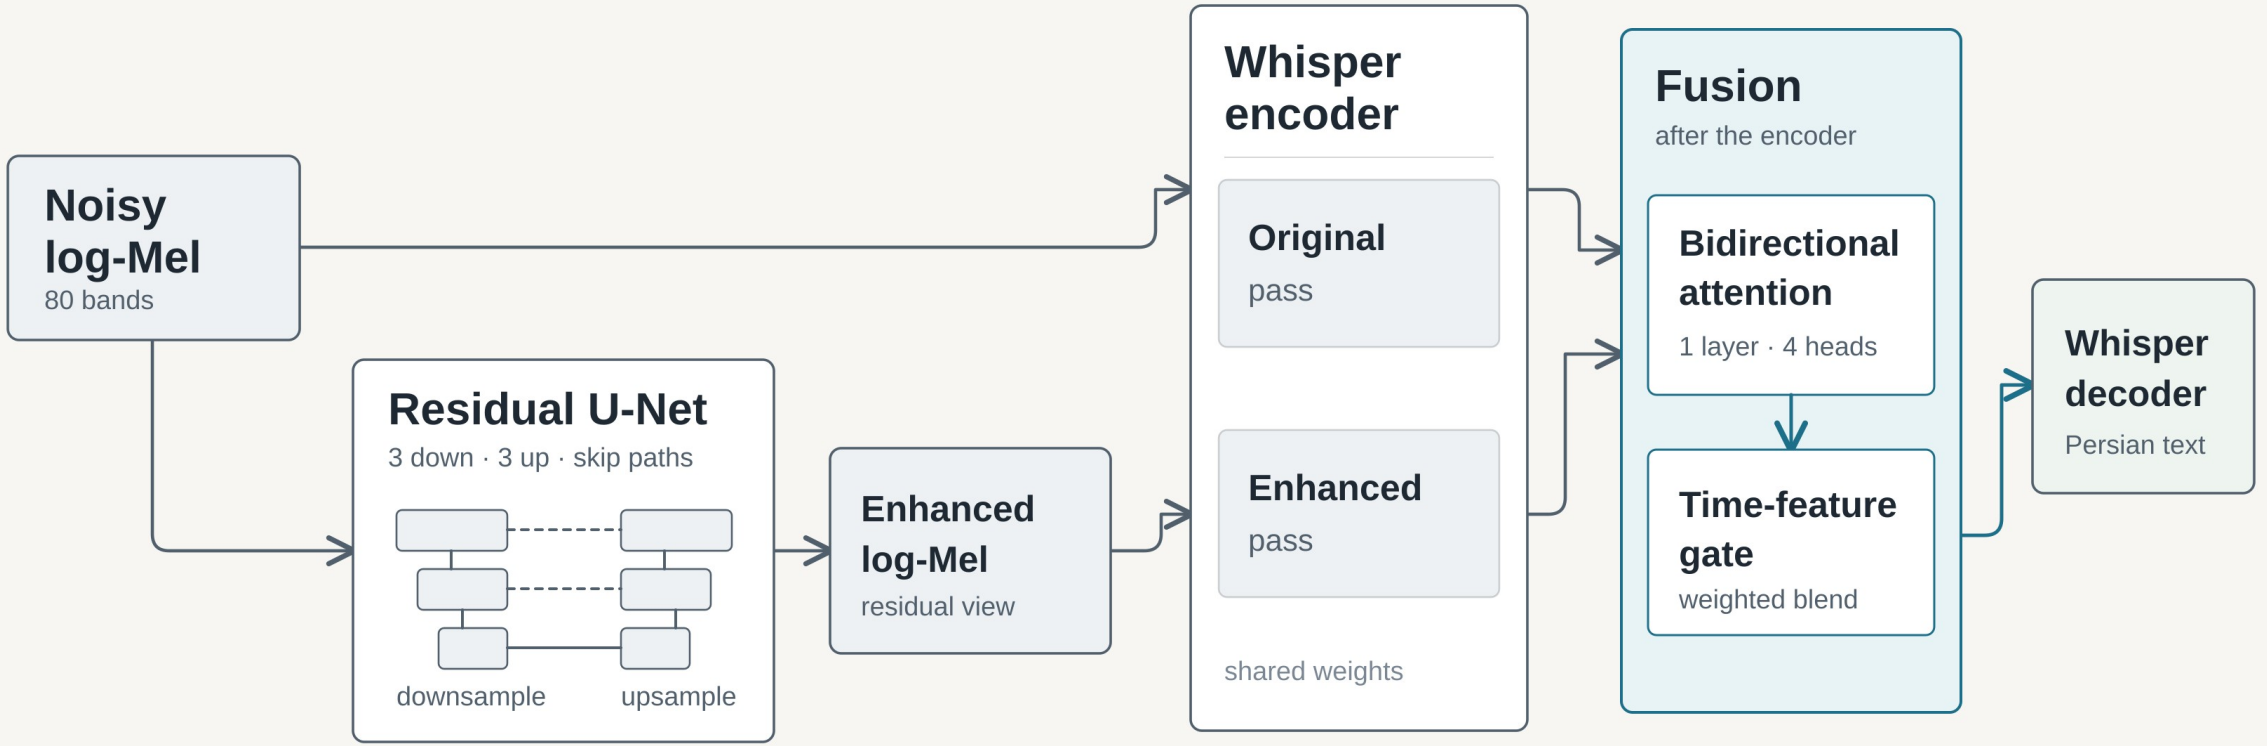
۲۷٫۶٪ کاهش نسبی

WER تجمیعی نیز از ۲۳٫۲۷٪ به ۱۷٫۸۳٪ کاهش یافت. مقدار کمتر بهتر است

اثر جداگانه کدک و اختلال شبکه در آزمایش حذفی سنجیده نشده است

# معماری بهسازی و همجوشی دوجریانه

حفظ نمای اصلی در کنار نمای بهسازی‌شده




شروع از ویسپر کوچک چندشرایطی است. بهساز در حوزه لاگ‌مل کار می‌کند و موج صوتی بازسازی نمی‌کند

# آموزش سه‌مرحله‌ای همجوشی




$L_{enh}$: log-Mel reconstruction · $L_{feat}$: encoder-feature matching · $L_{ASR}$: transcription loss

## مرحله سوم: آموزش همه اجزا، شامل ویسپر

### هر مرحله یک دوره کامل

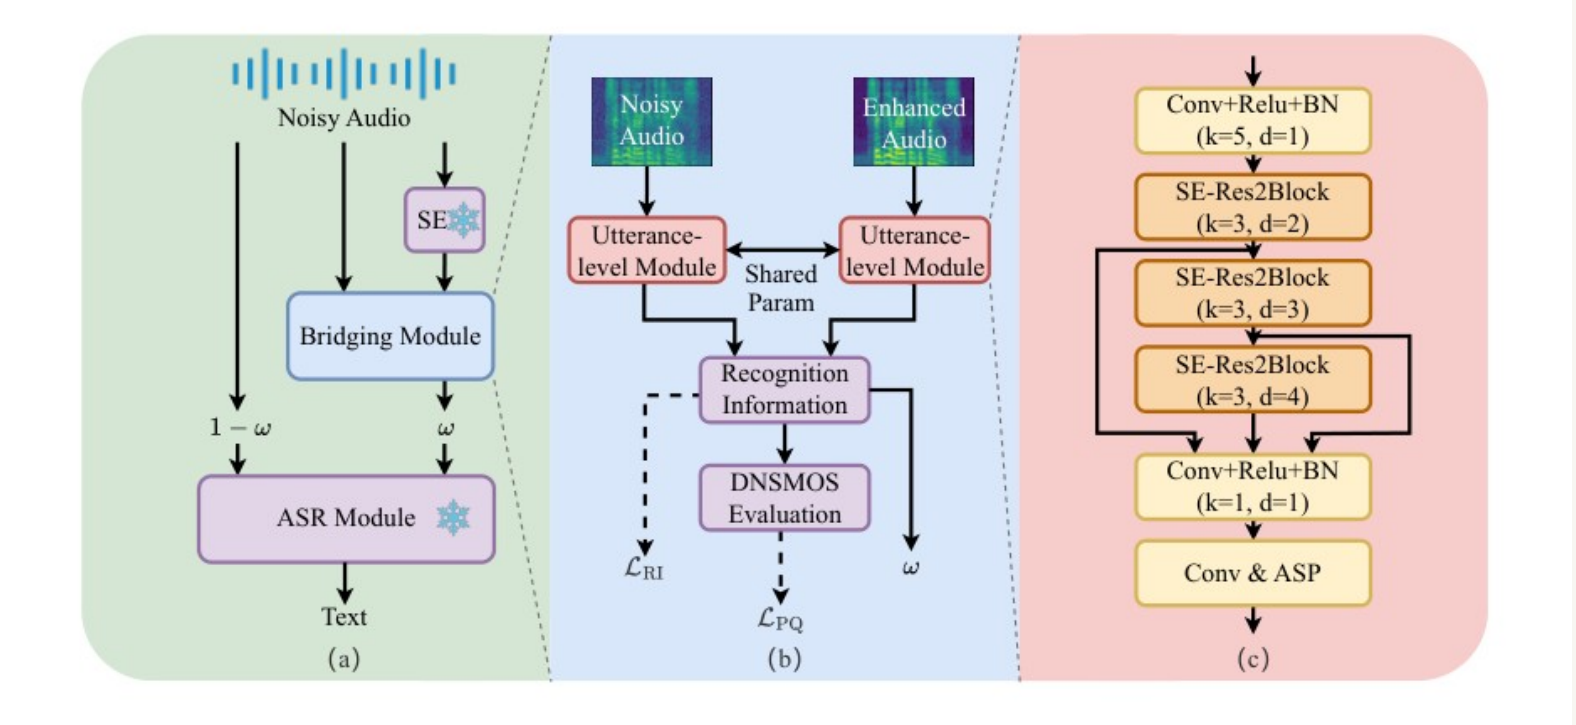
نرخ نهایی: ماژول‌های جدید 1e-4
ویسپر 5e-6

### داده مرحله نهایی

نمونه‌های تخریب‌شده و بلند
زیرمجموعه تصادفی ۲۵٪ از گفتار پاک

این آزمایش هم معماری و هم برنامه آموزش بازشناس را تغییر می‌دهد

# پل تطبیقی پیش از بازشناسی




Cui et al., ICASSP 2025, Fig. 1 (CC BY 4.0)

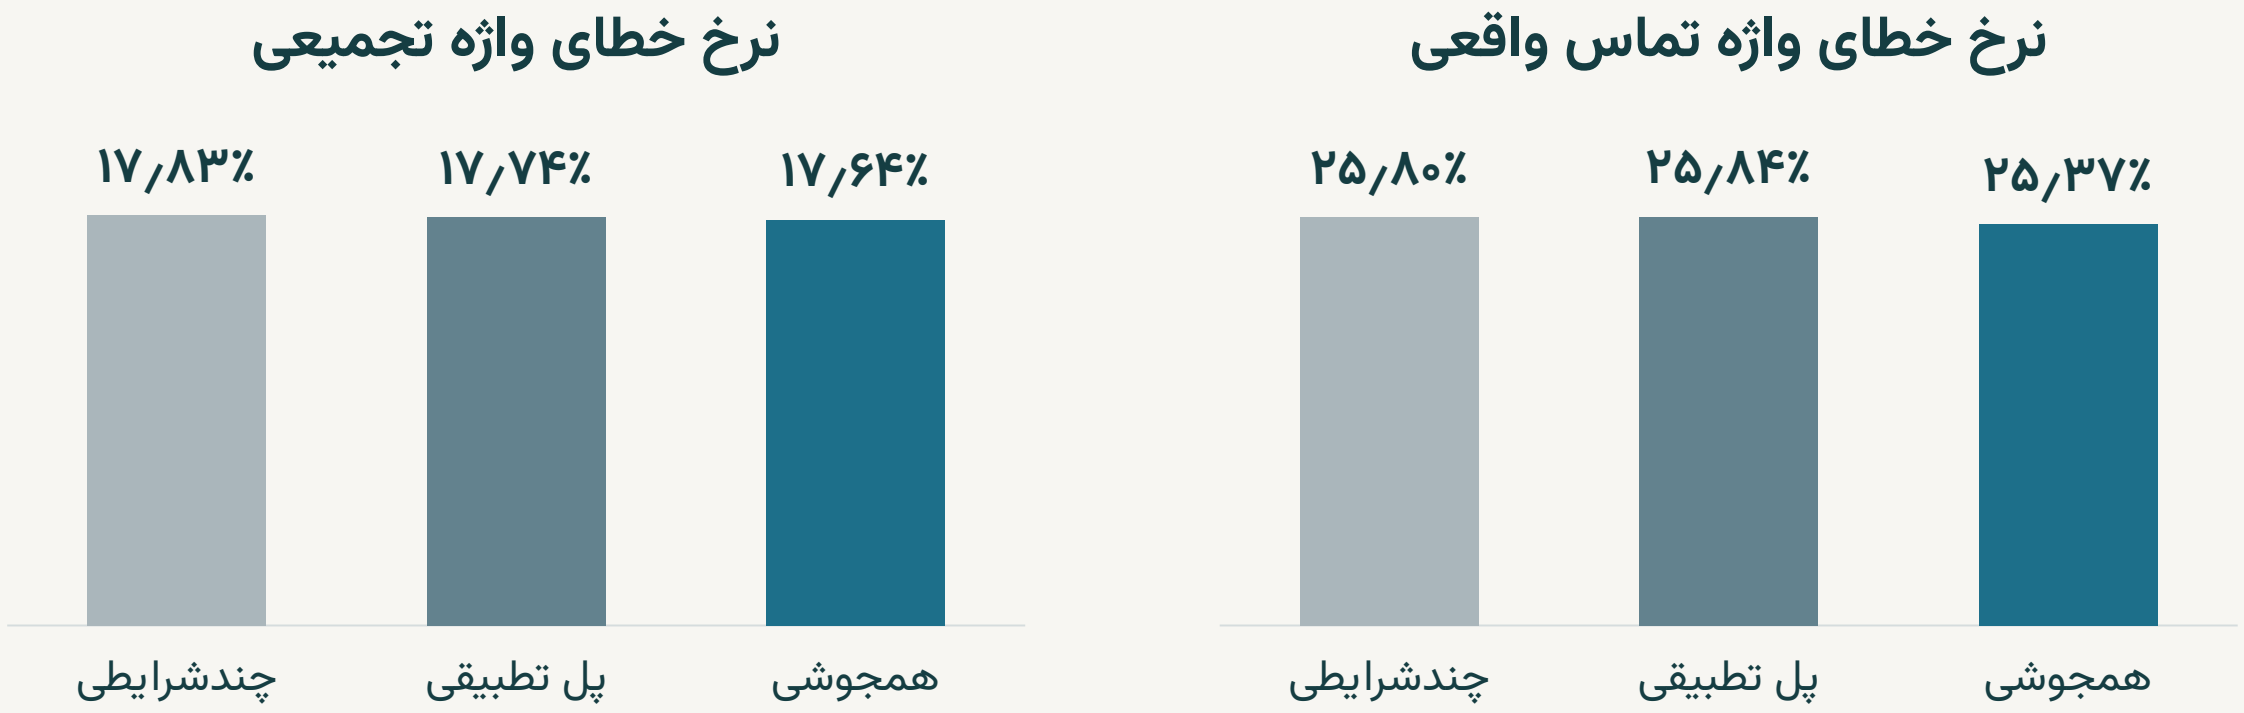
## پیاده‌سازی این پایان‌نامه

بهساز FRCRN ثابت
بازشناس ویسپر ثابت
آموزش فقط ماژول پل

**یک ضریب ترکیب**
**برای هر گفتار**

اجرای مستقل فارسی است. تفاوت بهساز و برنامه آموزش، انتساب اثر به محل ادغام را محدود می‌کند

# سود افزوده همجوشی و پل تطبیقی

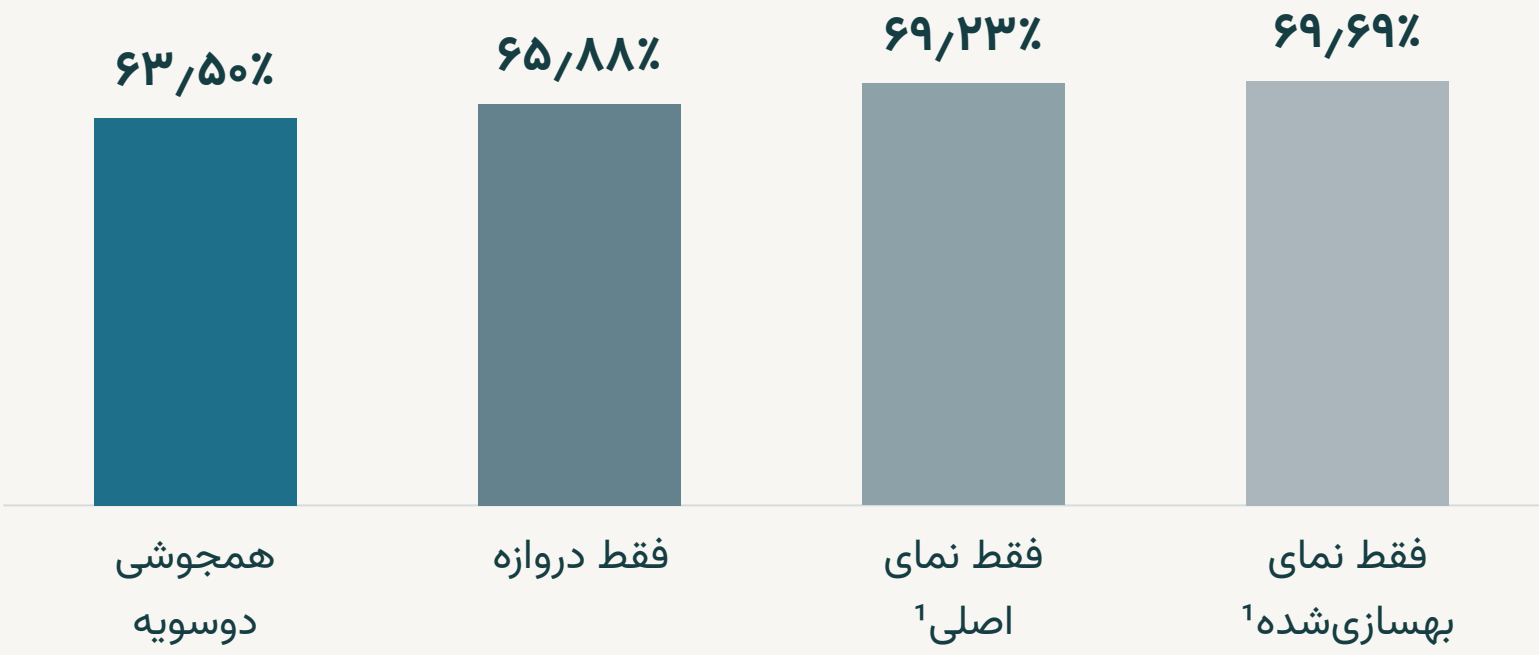



**کاهش WER با همجوشی: ۰٫۱۹ واحد درصد تجمیعی و ۰٫۴۳ واحد درصد در تماس واقعی**

CER تجمیعی به همین ترتیب: ۷٫۹۳٪، ۸٫۰۰٪ و ۷٫۸۵٪. اختلاف‌ها فاصله اطمینان ندارند

# آزمایش حذفیِ دو نما و توجه متقاطع

## نرخ خطای واژه در AGFarsdat




**آزمایش مستقل ویسپر بسیار کوچک**

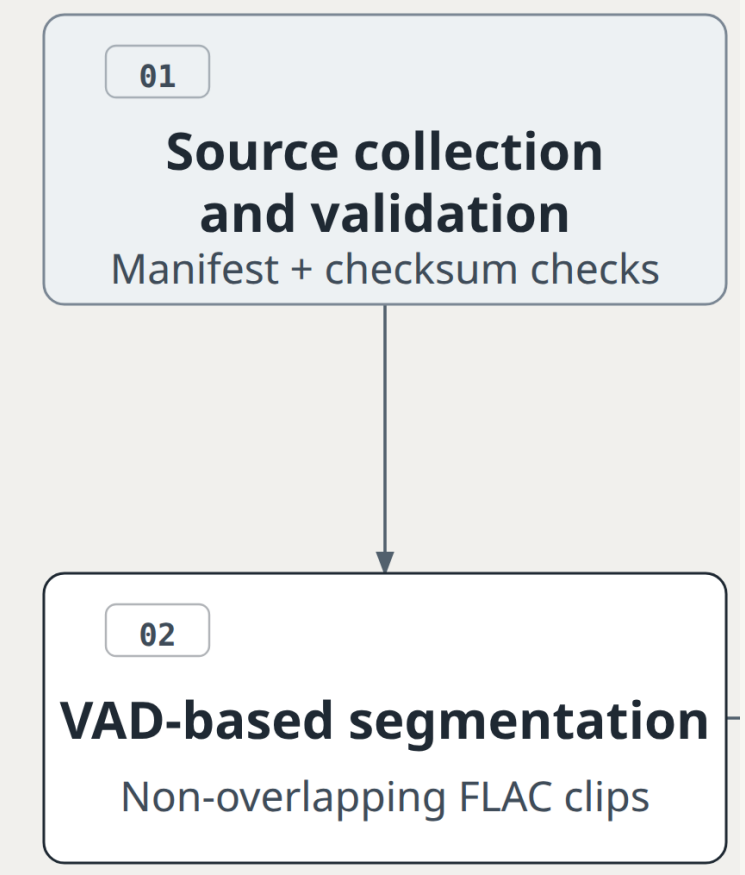
آموزش فقط با کامن‌وویس

**WER کامن‌وویس به ترتیب نمودار**

۵۷٫۸۲، ۶۲٫۳۵، ۶۴٫۱۰، ۶۳٫۸۱ درصد

[1] حذف نما در زمان استنتاج از مدل همجوشی آموزش‌دیده، نه آموزش مستقل یک مدل تک‌جریانه بودجه آموزش و تعداد پارامترهای نابرابر، تعیین سهم مستقل مؤلفه‌ها را محدود می‌کند

# گردآوری و قطعه‌بندی ایران‌صدا




## ۳,۷۷۷ کتاب صوتی

حدود ۶,۳۰۰ ساعت صوت خام دریافت‌شده

## ۲۵۰ ساعت منتخب

طول هدف قطعه‌ها ۲۰ ثانیه است
بازه ترجیحی ۱۵ تا ۲۵، سقف سخت ۲۸ ثانیه

مجموعه گردآوری‌شده از زیرمجموعه انتخاب‌شده برای آموزش بزرگ‌تر است

# رونویسی معلم، پالایش و آموزش

### ۱. رونویسی معلم

03

**Whisper-Medium ASR**

Raw pseudo-labels per clip

### ۲. نرمال‌سازی فارسی

04

**Deterministic Persian normalization**

Persian text conventions

### ۳. اصلاح با Qwen

05

**LLM refinement**

Qwen-based text correction

### ۴. پالایش کیفیت

06

**Quality filtering**

Reject invalid audio, labels, and Qwen edits

**افزودن داده پذیرفته‌شده به ترکیب کامل گفتار معمولی، بلند و تخریب‌شده**

معماری ویسپر کوچک، تنظیمات اصلی و تعداد گام‌های آموزش ثابت‌اند

# داده پذیرفته‌شده و ملاحظات برچسب

## ۳۹,۴۵۴

### قطعه پذیرفته‌شده

## ۲۱۸/۵۶۴ ساعت

۴۴,۸۲۰ بررسی‌شده، ۵,۳۶۶ ردشده
۱۳۶ فایل منبع، تفکیک در سطح کتاب

ترجمه بخشی از دستور پالایش

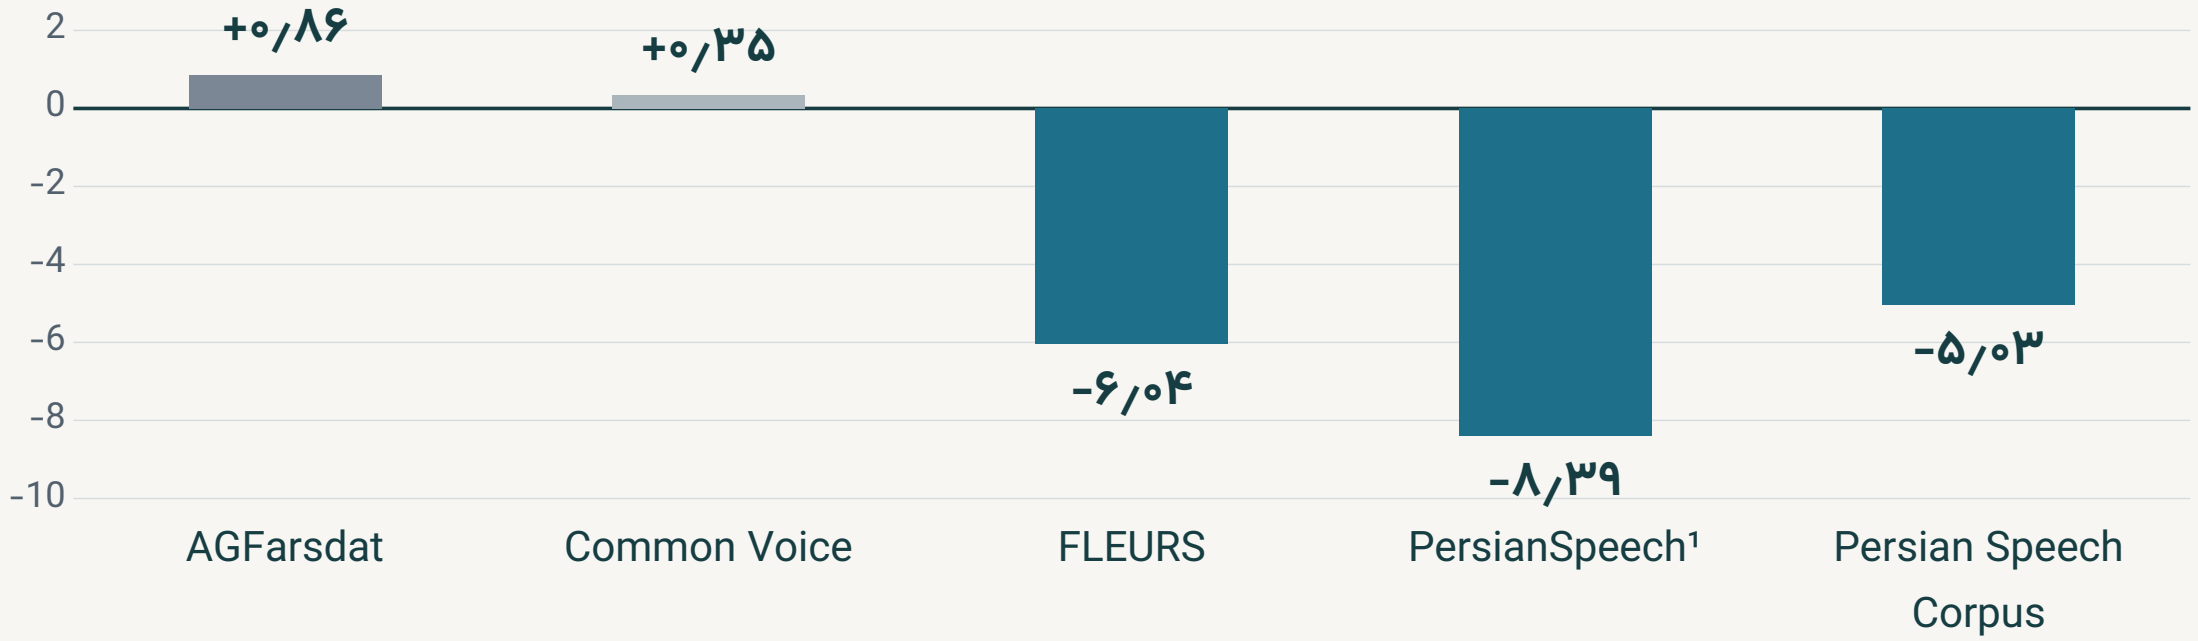
**«همه نشانه‌های عددی را دقیقاً با همان رقم‌ها، علامت‌ها، جداکننده‌ها و قالب حفظ کن.»**

Qwen فقط متن و بافت را دریافت می‌کند
رد موارد نامطمئن یا تغییرات بیش از حد
حفظ متن خام در کنار نسخه اصلاح‌شده

ممیزی انسانی کمّی برای دقت رونویسی انجام نشده است. ۴۰ شکست عملیاتی جداگانه ثبت شده‌اند

# اثر ایران‌صدا به دامنه گفتار وابسته است

تغییر WER نسبت به مدل چندشرایطی، بر حسب واحد درصد




**مقدار منفی یعنی بهبود. تغییر = با ایران‌صدا منهای خط مبنای چندشرایطی**

تجمیعی: WER از ۱۷٫۸۳٪ به ۱۷٫۲۲٪ و CER از ۷٫۹۳٪ به ۷٫۷۰٪ رسید

¹ فقط ۲۴ نمونه. اثر سبک، کانال، کیفیت برچسب و نسبت نمونه‌برداری از هم جدا نشده است

# نتیجه آزمایش‌های اصلی ویسپر کوچک

| سامانه ویسپر کوچک | WER تجمیعی | WER تماس واقعی |
|---|---|---|
| معمولی | ۲۳٫۲۷٪ | ۳۵٫۶۳٪ |
| چندشرایطی | ۱۷٫۸۳٪ | ۲۵٫۸۰٪ |
| همجوشی پیشنهادی | ۱۷٫۶۴٪ | **۲۵٫۳۷٪** |
| چندشرایطی و ایران‌صدا | **۱۷٫۲۲٪** | ۲۶٫۶۶٪ |

**کمترین خطای تجمیعی: ایران‌صدا**

**کمترین خطای تماس واقعی: همجوشی**

ویسپر متوسط: ۱۴٫۳۶٪ تجمیعی و ۲۱٫۹۹٪ تماس واقعی، با ظرفیت و آموزش متفاوت

# محدودیت‌ها و آزمایش‌های بعدی

| | | |
|---|---|---|
| ۱ | اعتمادپذیری نتایج | اجرای چندبذری و نمونه‌های مشترک دقیق برآورد فاصله اطمینان برای اختلاف‌های کوچک |
| ۲ | سهم و هزینه همجوشی | کنترل با بودجه آموزش برابر و آزمایش حذفی در Small اندازه‌گیری زمان اجرا و حافظه |
| ۳ | کیفیت و تناسب داده | ممیزی انسانی متن معلم و اصلاح‌های مدل زبانی آزمایش نسبت داده و گفتار نزدیک به تماس |

پوشش محدود شبیه‌ساز و خصوصی‌بودن آزمون تماس واقعی نیز دامنه شواهد را محدود می‌کنند

# جمع‌بندی

## بیشترین بهبود با آموزش متناسب با کانال

**۳۵٫۶۳٪** به **۲۵٫۸۰٪**

نرخ خطای واژه در تماس‌های واقعی مستقل

### همجوشی

۲۵٫۳۷٪ خطای تماس واقعی
بهبود عددی کوچک

### داده کتاب صوتی

۱۷٫۲۲٪ خطای تجمیعی
سود وابسته به دامنه

**سپاسگزارم
پرسش‌ها**

# مطالب تکمیلی

جزئیات داده‌ها و نتایج پژوهش

# اندازه پیکره‌ها و تنظیمات خط مبنا

| پیکره پایه | آموزش | اعتبارسنجی | نقش در آموزش |
|---|---|---|---|
| کامن‌وویس فارسی ۲۵ | ۲۹۹۴۳۰ | ۱۰۰۰۶ | گفتار عمومی و تولید تخریب |
| فارس‌اسپان (محدود) | ۶۰۰۶۷۲ | ۶۰۴۴ | گفتار بداهه فارسی |
| فلورز فارسی | ۳۰۱۹ | ۳۶۲ | تنوع دامنه |

## ویسپر کوچک تک‌جریانه

یک دوره، نرخ یادگیری 1e-5
دسته ۴ و انباشت ۸ گام: ۳۲ نمونه

## جزئیات آزمون AGFarsdat

۵۸۵ گوینده و ۴۹٫۹ ساعت
صوت منبع: تک‌کاناله، ۸ کیلوهرتز، ۱۶ بیت

تعدادها مربوط به پیکره پایه‌اند. گونه‌های بلند، تخریب‌شده و ایران‌صدا در این جدول نیستند

# نرخ خطای واژه به تفکیک مجموعه

| سامانه | AGFarsdat | کامن‌وویس ۲۵ | فلورز | پرشین‌اسپیچ[1] | پیکره گفتار فارسی |
|---|---|---|---|---|---|
| معمولی | ۳۵٫۶۳٪ | ۱۱٫۵۲٪ | ۲۱٫۰۵٪ | ۳۴٫۵۳٪ | ۳۰٫۱۷٪ |
| داده‌افزایی نویزی | ۳۲٫۶۷٪ | ۷٫۸۶٪ | ۱۹٫۲۶٪ | ۳۳٫۵۷٪ | ۳۰٫۴۷٪ |
| pMCT | ۳۰٫۰۱٪ | ۷٫۲۵٪ | ۲۰٫۲۳٪ | ۳۱٫۶۵٪ | ۳۰٫۵۰٪ |
| چندشرایطی | ۲۵٫۸۰٪ | ۷٫۸۴٪ | ۱۹٫۸۲٪ | ۳۵٫۲۵٪ | ۳۰٫۹۰٪ |
| همجوشی دوجریانه | ۲۵٫۳۷٪ | ۷٫۵۳٪ | ۱۹٫۶۷٪ | ۳۱٫۸۱٪ | ۳۳٫۸۲٪ |
| پل تطبیقی | ۲۵٫۸۴٪ | ۷٫۶۳٪ | ۱۹٫۷۳٪ | ۳۵٫۰۹٪ | ۳۲٫۳۲٪ |
| ویسپر متوسط | **۲۱٫۹۹٪** | **۳٫۸۴٪** | ۱۷٫۱۴٪ | ۳۱٫۶۵٪ | ۳۱٫۱۷٪ |
| چندشرایطی و ایران‌صدا | ۲۶٫۶۶٪ | ۸٫۱۹٪ | **۱۳٫۷۸٪** | **۲۶٫۸۶٪** | **۲۵٫۸۷٪** |

همه اعداد WER و درصد هستند. [1] فقط ۲۴ نمونه. تعداد واجدشرایط پیکره گفتار فارسی تغییر می‌کند

# آموزش چندشرایطی در فست کانفورمر

| مجموعه آزمون | WER معمولی | CER معمولی | WER چندشرایطی | CER چندشرایطی |
|---|---|---|---|---|
| تجمیعی | ۲۲٫۷۳٪ | ۱۴٫۷۹٪ | ۲۱٫۸۱٪ | ۱۴٫۴۵٪ |
| AGFarsdat | ۳۱٫۰۷٪ | ۱۴٫۸۱٪ | ۳۰٫۴۸٪ | ۱۴٫۰۹٪ |
| کامن‌وویس فارسی ۲۵ | ۱۱٫۶۸٪ | ۱۶٫۴۶٪ | ۱۰٫۰۱٪ | ۱۶٫۱۰٪ |
| فلورز فارسی | ۲۹٫۲۲٪ | ۹٫۹۴٪ | ۲۹٫۴۰٪ | ۱۰٫۲۲٪ |
| پرشین‌اسپیچ | ۳۰٫۷۰٪ | ۱۳٫۵۰٪ | ۳۱٫۴۱٪ | ۱۳٫۵۶٪ |
| پیکره گفتار فارسی | ۳۳٫۶۹٪ | ۱۲٫۲۲٪ | ۳۳٫۵۹٪ | ۱۲٫۶۸٪ |

## کاهش WER تجمیعی: ۰٫۹۲ واحد درصد، حدود ۴٪ کاهش نسبی

مقایسه درون فست کانفورمر است. تفاوت پیش‌آموزش و آموزش، انتساب فاصله با ویسپر را محدود می‌کند

# آزمایش کامل مؤلفه‌ها در ویسپر بسیار کوچک

| پیکربندی | Common Voice WER | Common Voice CER | AGFarsdat WER | AGFarsdat CER |
|---|---|---|---|---|
| خط مبنای چندشرایطی | ۷۴٫۹۲٪ | ۳۸٫۰۳٪ | ۷۶٫۸۵٪ | ۳۵٫۰۴٪ |
| همجوشی فقط دروازه‌ای | ۶۲٫۳۵٪ | ۳۲٫۸۷٪ | ۶۵٫۸۸٪ | ۲۸٫۴۲٪ |
| توجه متقاطع باقیمانده | ۶۰٫۲۶٪ | ۳۱٫۹۰٪ | ۶۵٫۴۸٪ | ۲۸٫۳۵٪ |
| فقط نمای اصلی[1] | ۶۴٫۱۰٪ | ۳۳٫۲۱٪ | ۶۹٫۲۳٪ | ۳۰٫۳۹٪ |
| فقط نمای بهسازی‌شده[1] | ۶۳٫۸۱٪ | ۳۳٫۰۵٪ | ۶۹٫۶۹٪ | ۳۰٫۷۳٪ |
| همجوشی دوسویه | **۵۷٫۸۲٪** | **۳۰٫۵۷٪** | **۶۳٫۵۰٪** | **۲۷٫۰۲٪** |
| پل: فقط PQ | ۷۴٫۴۸٪ | ۳۷٫۸۱٪ | ۷۶٫۶۳٪ | ۳۴٫۸۳٪ |
| پل: فقط صوت بهسازی‌شده | ۷۵٫۹۰٪ | ۳۸٫۷۹٪ | ۷۷٫۶۷٪ | ۳۵٫۵۳٪ |
| پل: PQ + RI | ۷۴٫۴۰٪ | ۳۷٫۸۱٪ | ۷۶٫۸۱٪ | ۳۴٫۹۴٪ |

[1] حذف مسیر در استنتاج. آموزش فقط با کامن‌وویس است. بودجه آموزش و ظرفیت گونه‌ها برابر نیست

# مقایسه مدل‌ها روی زیرمجموعه مشترک

| مدل | WER تجمیعی | CER تجمیعی | WER تماس واقعی |
|---|---|---|---|
| Chirp 3 | ۱۶٫۴۴٪ | ۵٫۱۴٪ | ۲۲٫۹۴٪ |
| GPT-4o Transcribe | ۱۸٫۵۵٪ | ۶٫۹۴٪ | ۴۸٫۶۲٪ |
| کوچک: چندشرایطی و ایران‌صدا | ۲۰٫۷۲٪ | ۱۰٫۷۲٪ | ۲۶٫۶۱٪ |
| همجوشی دوجریانه | ۲۱٫۷۲٪ | ۱۰٫۹۷٪ | ۲۵٫۳۱٪ |
| ویسپر متوسط | ۲۳٫۱۳٪ | ۱۱٫۲۴٪ | ۲۴٫۷۷٪ |
| Voxtral Small 24B | ۲۶٫۹۲٪ | ۱۰٫۷۵٪ | ۴۵٫۸۷٪ |
| Qwen3-ASR 1.7B | ۳۶٫۶۶٪ | ۱۵٫۶۸٪ | ۶۳٫۳۰٪ |
| Grok STT 1.0 | ۴۰٫۸۸٪ | ۲۳٫۶۸٪ | ۶۷٫۸۹٪ |
| Nemotron 3.5 ASR 0.6B | ۹۸٫۷۰٪ | ۸۰٫۸۶٪ | ۱۰۴٫۵۹٪ |

۱۰۰ نمونه ثابت، ۲۰ نمونه از هر مجموعه. این مقایسه جایگزین ارزیابی کامل نیست