دانشگاه صنعتی شریف

دانشکده مهندسی کامپیوتر

بازشناسی مقاوم گفتار در زبان فارسی

پویا فلاح سیچانی

استاد راهنما: دکتر حسین صامتی

دفاع پایان‌نامه کارشناسی ارشد

شکاف میان گفتار آموزشی و تماس واقعی

اعوجاج کدک (Codec Distortion) و افت بسته (Packet Loss) در تماس اینترنتی (VoIP)

گفتار در دسترس

پیکره‌های عمومیِ فارسی
قطعه‌های عمدتاً کوتاه
سبک‌ها و شرایط ضبط متنوع

شرایط تماس

نویز و پهنای‌باند محدود
اعوجاج کدک و افت بسته
تلفن و تماس اینترنتی

هدف: کاهش خطای تماس واقعی با داده‌های موجود

گردآوری تماس رونویسی‌شده پرهزینه و حساس به حریم خصوصی است

آموزش، سازگارسازی و اصلاح خروجی

آموزش چندشرایطی (Multi-condition Training)، داده‌افزایی (Data Augmentation) و ریزتنظیم (Fine-tuning)

خانواده روش	ایده اصلی	نمونه پژوهش‌ها
آموزش چندشرایطی و داده‌افزایی	آموزش با نویز و تخریب کانال، همراه با تنوع آکوستیکی هدفمند	pMCT (2022) Acoustic-aware Aug. (2025*)
انطباق مدل‌های پایه	ریزتنظیم کامل یا کم‌پارامتر، با داده متناسب با زبان و دامنه	MCAT–LoRA (2025) / SPS (2026) Neyshekar (2026*)
یادگیری خودنظارتی و نیمه‌نظارتی	پیش‌آموزش با صوت بی‌برچسب، خودتقطیر و پالایش شبه‌برچسب‌ها	Bhogale et al. (2024) Cross-lingual (2025) / DASH (2026)
اصلاح با مدل زبانی	اصلاح فرضیه‌های بازشناس با مدل زبانی و شواهد صوتی	ClozeGER / Listen Again (2024) Conservative Filtering (2024)

ارزیابی‌های جدید Speech Robust Bench (2025) URGENT (2025) PSRB (2025)

بهسازی گفتار و ادغام نماها

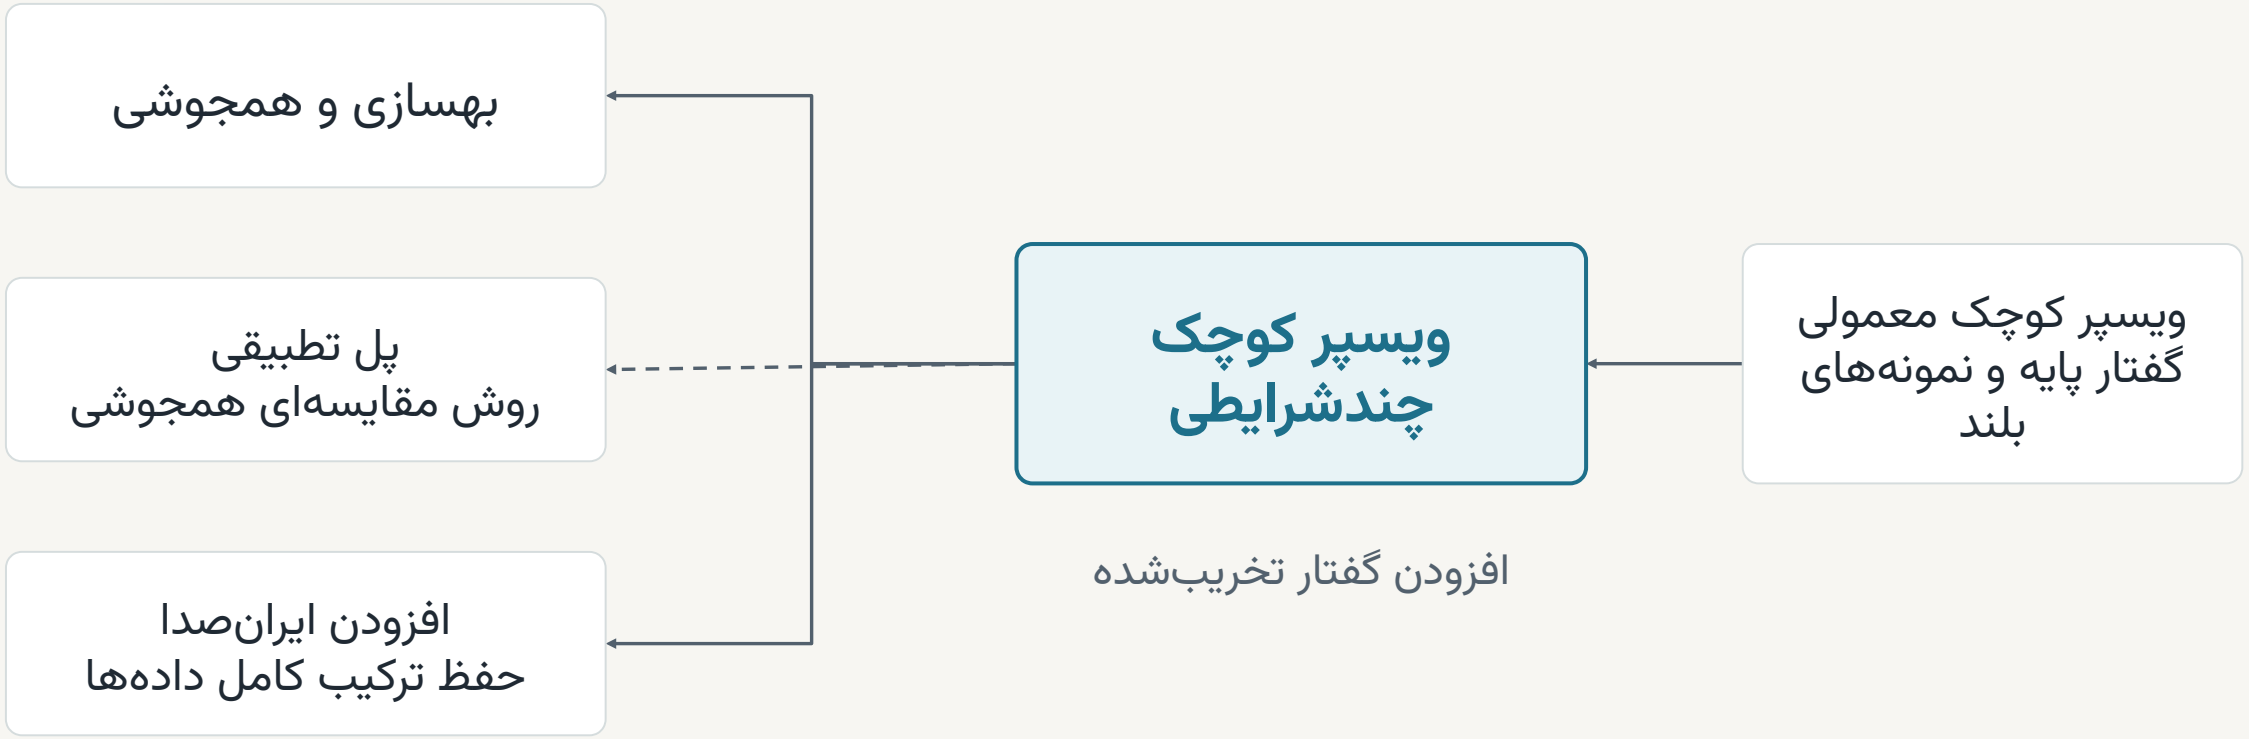
بهسازی گفتار (Speech Enhancement) و همجوشی بازنمایی‌ها (Representation Fusion)

خانواده روش	ایده اصلی	نمونه پژوهش‌ها
بهسازی پیش از بازشناسی	بازسازی گفتار با بهساز پیش‌بینی‌گر یا مولد پیش از بازشناسی	Schrödinger Bridge (2025) Decoupled SE–ASR (2026)
بهسازی وظیفه‌محور	آموزش بهساز با زیان بازشناسی یا بازنمایی‌های خودنظارتی	Dissen et al. (2025) SSL-MSE / Sato et al. (2025)
همجوشی در فضای بازنمایی	تعامل و ترکیب ویژگی‌های بازنمایی اصلی و بهسازی‌شده	FAT-HuBERT (2023) Wav2code (2024)
ترکیب در سطح موج	آمیختن تطبیقی دو موج با پل، اطمینان بازشناس یا پالایش قطعه‌ای	Adaptive Bridge (2024, 2025) Conf-OA / Rethink-and-Refine (2026)

افزایش کیفیت شنیداری الزاماً به کاهش خطای بازشناسی منجر نمی‌شود

ساختار آزمایش‌ها و خط مبنا

خط مبنا (Baseline)، همجوشی دوجریانه (Dual-stream Fusion) و شبه‌برچسب‌گذاری (Pseudo-labeling)



همجوشی و ایران‌صدا دو مسیر مستقل‌اند. سامانه ترکیبی آن‌ها ارزیابی نشده است

داده‌های آموزش

گفتار پایه فارسی

پیکره	آموزش (نمونه)	اعتبارسنجی (نمونه)
Common Voice 25	۲۹۹,۴۳۰	۱۰,۰۰۶
FarsSpon	۶۰۰,۶۷۲	۶,۰۴۴
FLEURS Persian	۳,۰۱۹	۳۶۲
مجموع	**۹۰۳,۱۲۱**	**۱۶,۴۱۲**

واحد شمارش جدول: نمونه گفتار (Utterance)، پیش از ساخت گونه‌های بلند و تخریب‌شده و افزودن ایران‌صدا

صوت تک‌کاناله ۱۶ کیلوهرتزی و نرمال‌سازی مشترک متن فارسی

۲ تا ۴

قطعه برای ساخت هر نمونه بلند

اتصال درون همان گروه داده
حداقل ۵ و حداکثر ۲۰ ثانیه
حضور در تمام آزمایش‌ها

ارزیابی روی تماس واقعی و گفتار عمومی

نرخ خطای واژه (Word Error Rate, WER)؛ اندازه هر مجموعه بر حسب نمونه گفتار (Utterance)

۱۰,۰۴۴

نمونه تماس واقعی در AGFarsdat

۵۸۵ گوینده و ۴۹٫۹ ساعت صوت
تلفن و تماس اینترنتی
مستقل از آموزش و انتخاب مدل

آزمون‌های گفتار عمومی

Common Voice Persian 25	۱۰,۵۱۸ نمونه
FLEURS Persian	۸۷۱ نمونه
PersianSpeech	۲۴ نمونه
Persian Speech Corpus	۳۹۱ نمونه

در مجموع، حدود ۱۱,۸۰۰ نمونه گفتار عمومی

نرخ خطای واژه (٪)

$$\text{WER}\ (\%) = 100 \times (S + D + I) / N$$

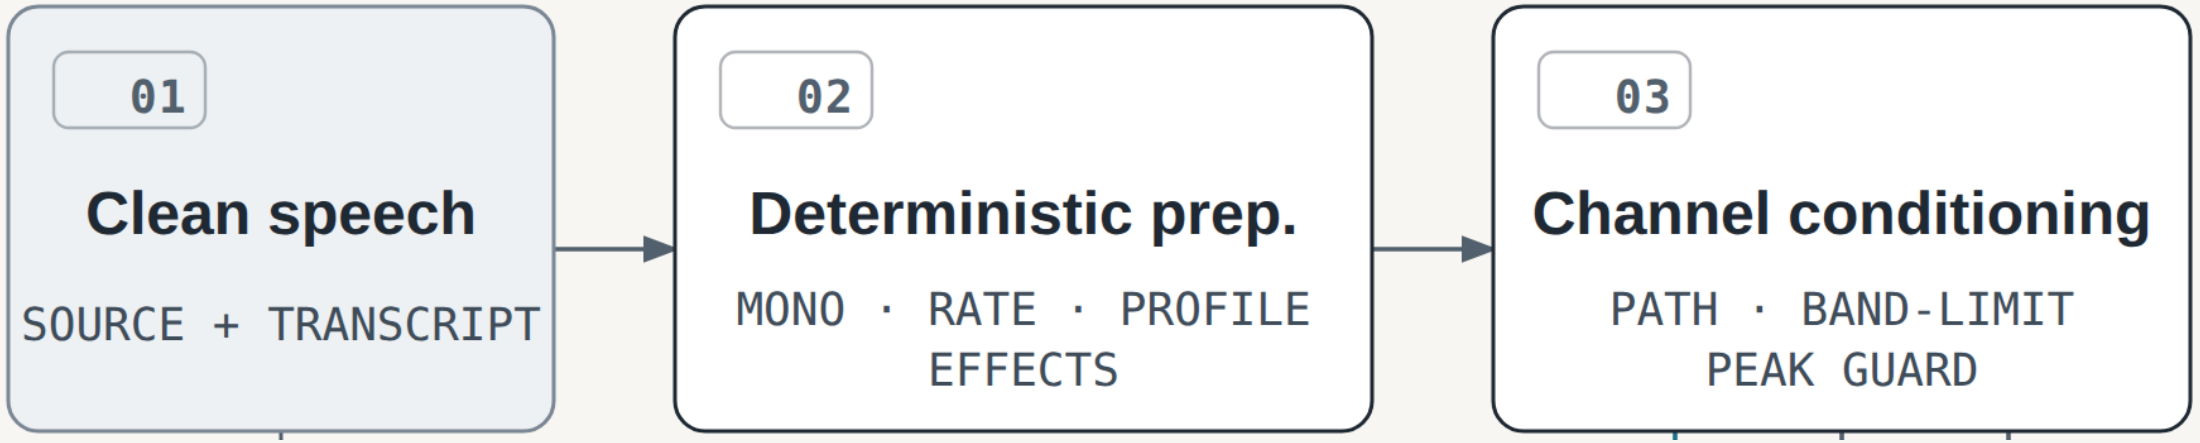
CER: Character Error Rate، نرخ خطای نویسه (٪)؛ تجمیع با جمع شمارش خطاها و واحدهای مرجع

تعداد نمونه‌های واجدشرایط در بعضی سامانه‌ها متفاوت است. رمزگشایی حریصانه مشترک است

داده‌افزایی مخابراتی

نسبت سیگنال به نویز (Signal-to-Noise Ratio, SNR) و تغییر بهره (Gain)، هر دو بر حسب دسی‌بل (dB)

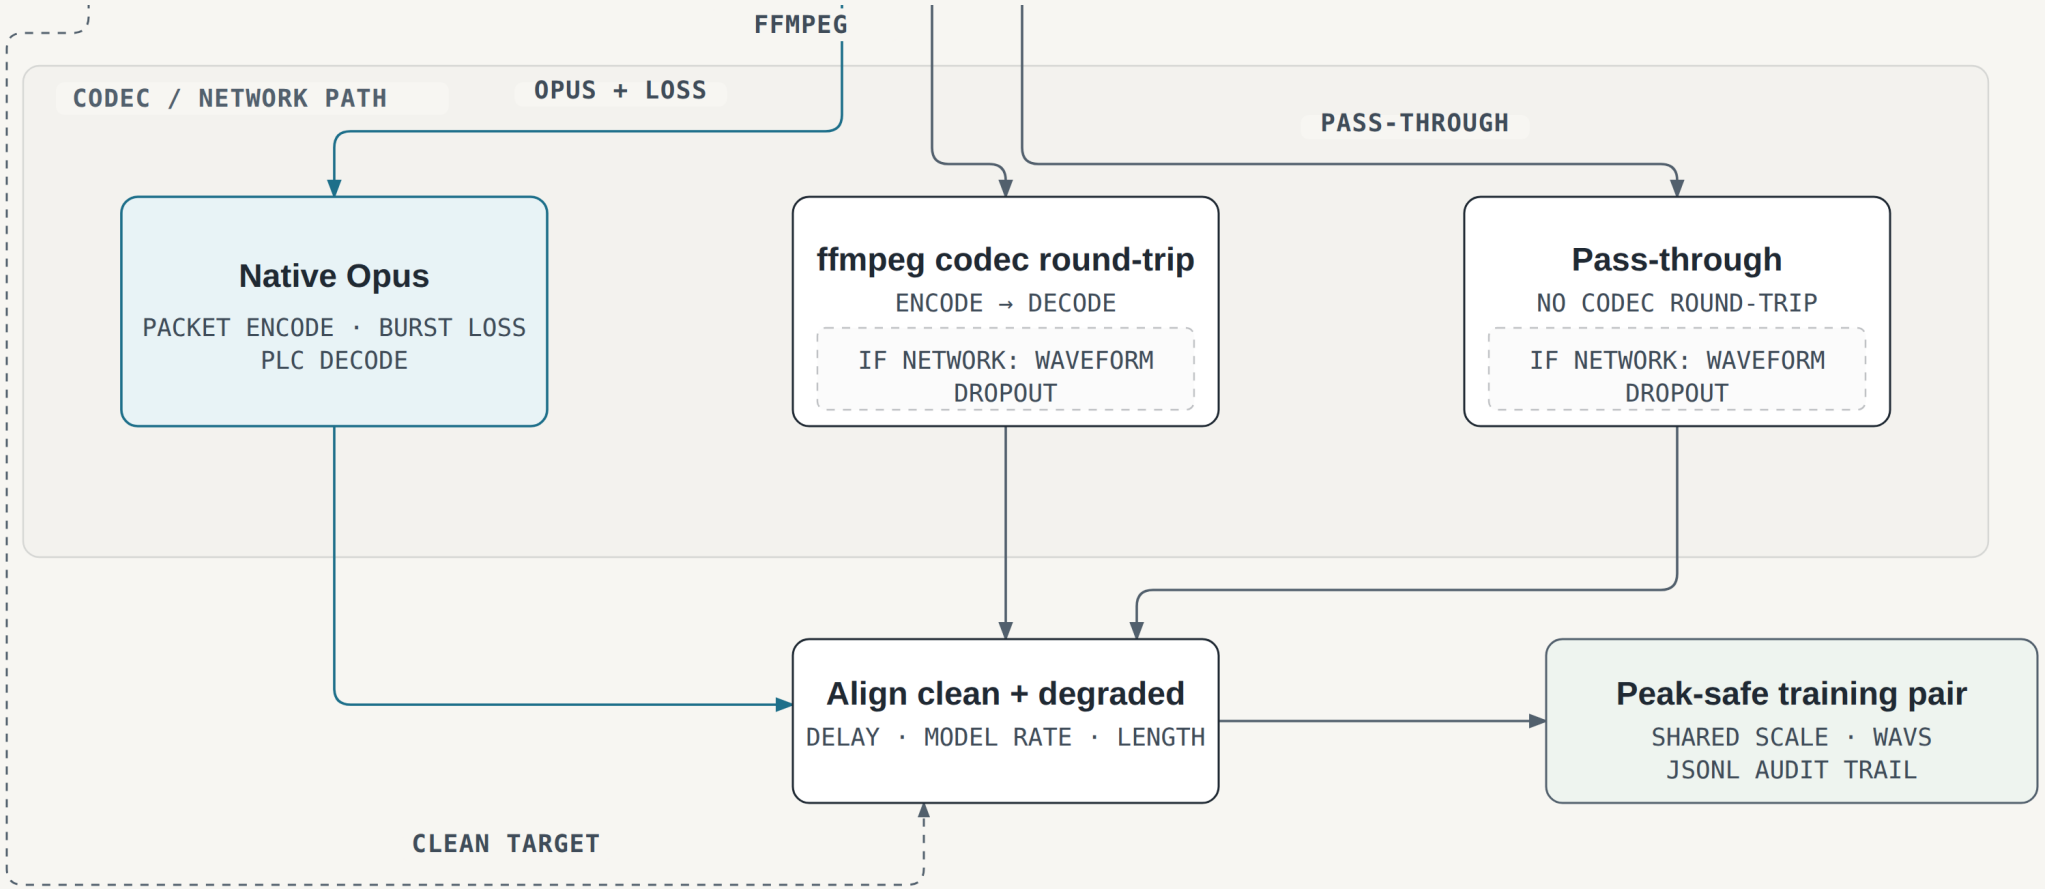
ساخت جفت‌های پاک و تخریب‌شده با رونویسی مشترک



نویز و تغییر بهره

DEMAND SNR: -5 … 15 dB Gain: ±6 dB

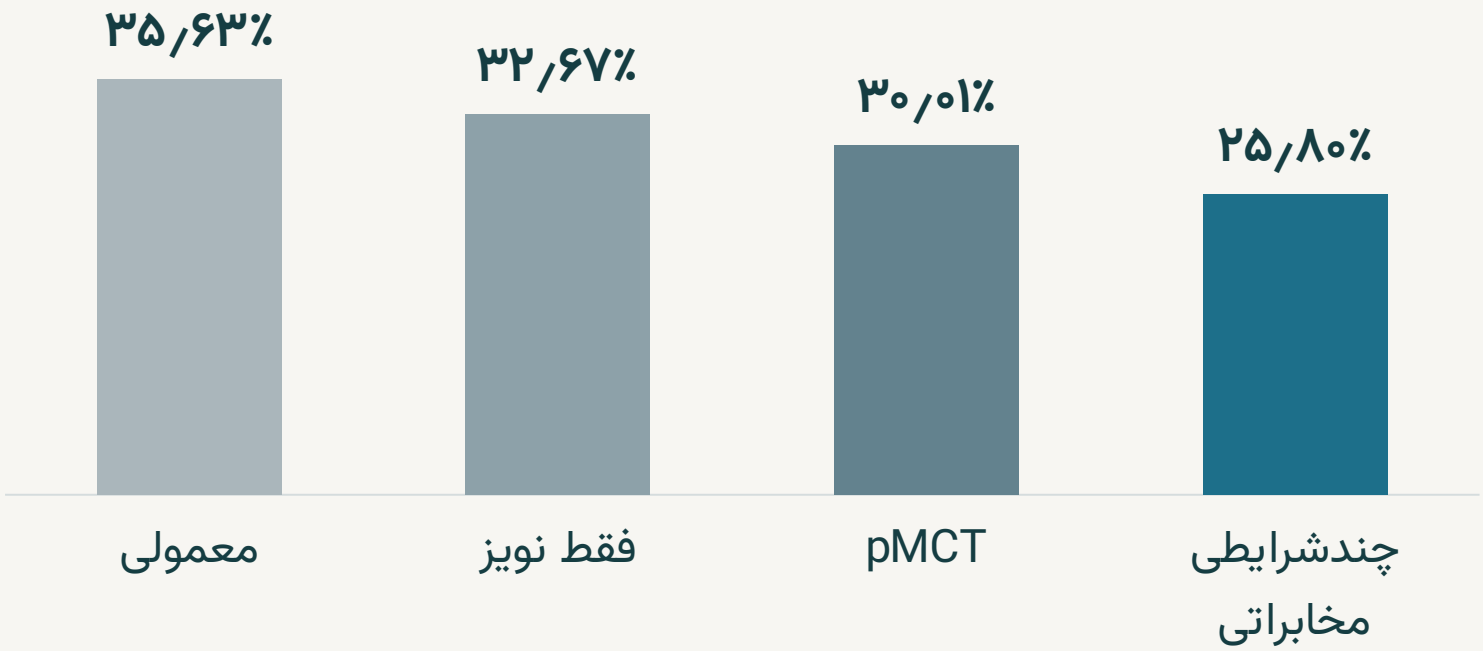
مسیرهای کدک و جفت‌های هم‌تراز



AMR-WB، AMR-NB، GSM، G.711 و Opus. هدف پاک، پهنای‌باند متناظر با کانال را حفظ می‌کند
Opus بومی افت بسته و پنهان‌سازی خطا را مدل می‌کند. در مسیرهای دیگر، حذف موج یک تقریب است

انتقال بهبود به تماس‌های واقعی

نرخ خطای واژه در AGFarsdat (٪)



۹٫۸۳

واحد درصد کاهش خطا در تماس‌های واقعی

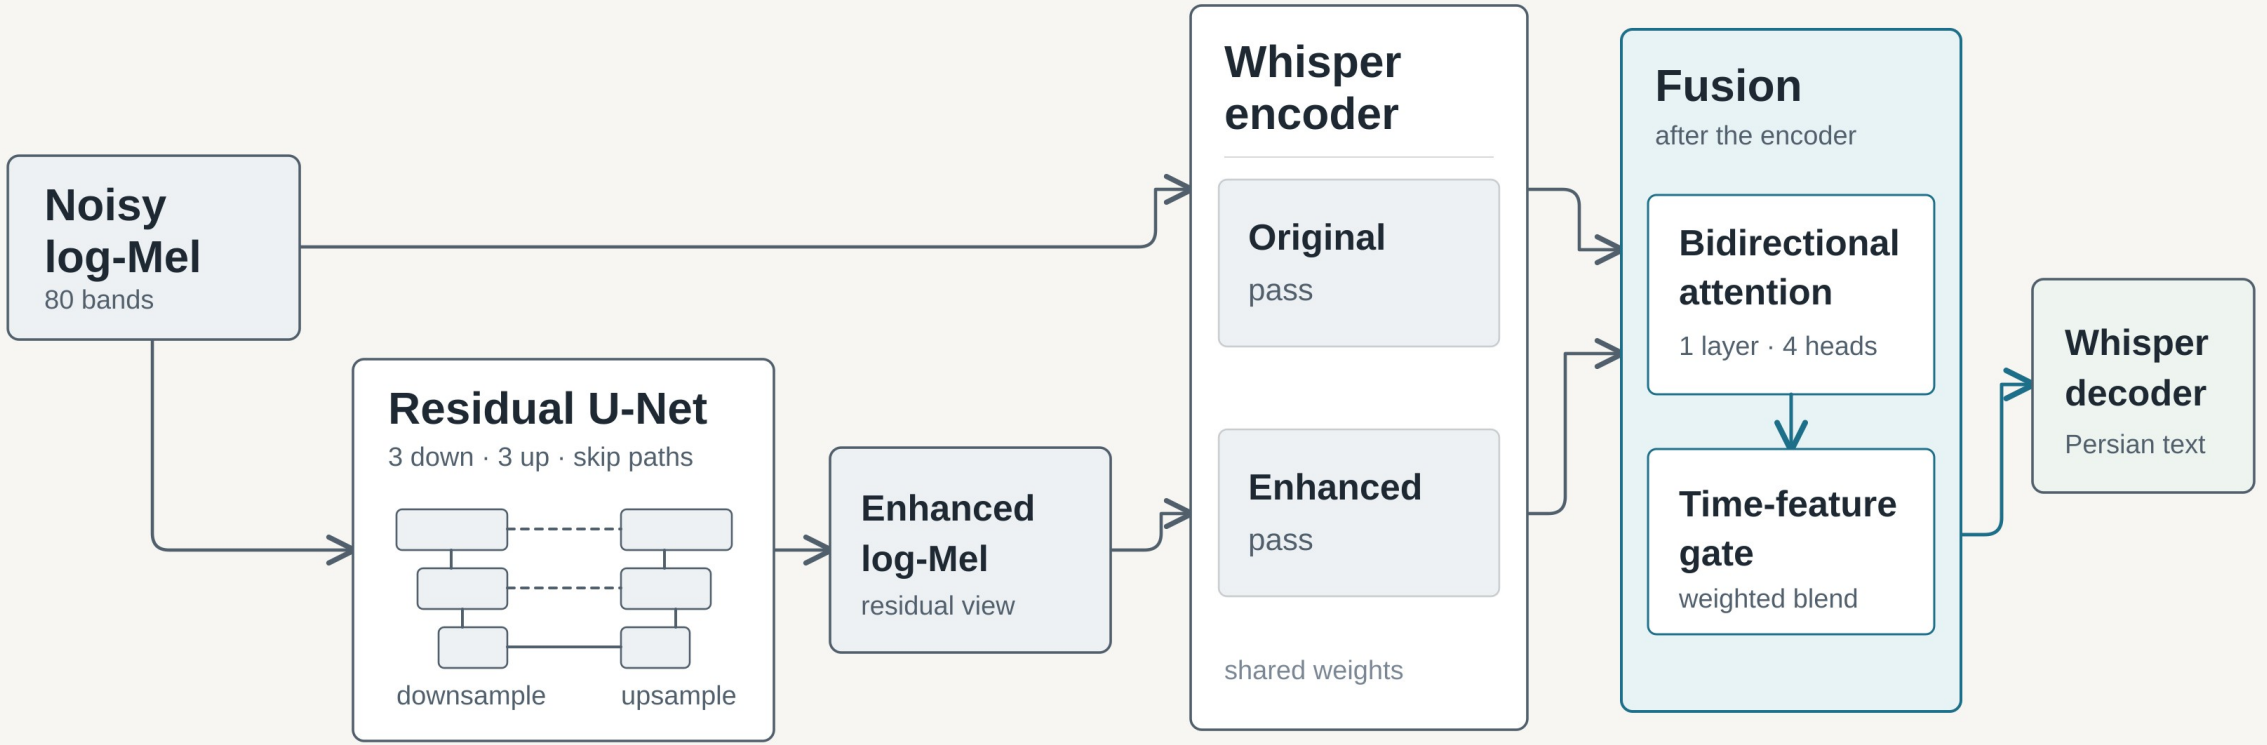
۲۷٫۶٪ کاهش نسبی

WER تجمیعی نیز از ۲۳٫۲۷٪ به ۱۷٫۸۳٪ کاهش یافت. مقدار کمتر بهتر است

اثر جداگانه کدک و اختلال شبکه در آزمایش حذفی سنجیده نشده است

معماری بهسازی و همجوشی دوجریانه

حفظ دو بازنمایی با توجه متقاطع دوسویه (Bidirectional Cross-attention) و دروازه (Gate)



شروع از ویسپر کوچک چندشرایطی است. بهساز در حوزه لاگ‌مل کار می‌کند و موج صوتی بازسازی نمی‌کند

روابط مدل بهسازی و همجوشی دوجریانه

رمزگذار مشترک ویسپر

$$H_n = Enc_\theta(M_n)$$

$$H_e = Enc_\theta(M_e)$$

توجه متقاطع دوسویه: هر نما از نمای مقابل اطلاعات می‌گیرد

تعریف مشترک بلوک B با ورودی‌های X و Y

$$Q = LN_q(X),\ K = V = LN_{kv}(Y)$$

$$Z = X + MHA(Q,K,V)$$

$$B(X,Y) = Z + FFN(LN(Z))$$

در هر سر، q و k و v پس از نگاشت خطی‌اند

دروازه (Gate) و ترکیب بازنمایی‌های اصلاح‌شده

$$H_f = g \odot H'_e + (1 - g) \odot H'_n$$

دو بلوک B وزن‌های مستقل دارند و هم‌زمان از ورودی‌های پیش از به‌روزرسانی استفاده می‌کنند

LN: Layer Normalization FFN: Feed-Forward Network 4 heads FFN: 2D features Gate: 0.5 (unitless)

بهسازی باقیمانده و زیان بازسازی

$$M_e = M_n + E(M_n)$$

$$\mathscr{L}_{enh} = \|M_e - M_c\|_1$$

$$H'_n = B_n(H_n, H_e)$$

Q: بازنمایی اصلی، K و V: بازنمایی بهسازی‌شده

$$H'_e = B_e(H_e, H_n)$$

Q: بازنمایی بهسازی‌شده، K و V: بازنمایی اصلی

$$Attn(q,k,v) = softmax(qk^T / \sqrt{d_k})v$$

$$g = \sigma(W_2\ GELU(W_1[H'_n; H'_e]))$$

آموزش سه‌مرحله‌ای همجوشی

گرم‌کردن بهساز (Enhancer Warm-up)، آموزش همجوشی (Fusion Training) و ریزتنظیم مشترک (Joint Fine-tuning)



L_{enh}: log-Mel reconstruction · L_{feat}: encoder-feature matching · L_{ASR}: transcription loss

مرحله سوم: آموزش همه اجزا، شامل ویسپر

هر مرحله: ۱ دوره کامل (Epoch)

نرخ یادگیری مرحله نهایی (بی‌واحد)

ماژول‌های جدید: ۰٫۰۰۰۱؛ ویسپر: ۰٫۰۰۰۰۰۵

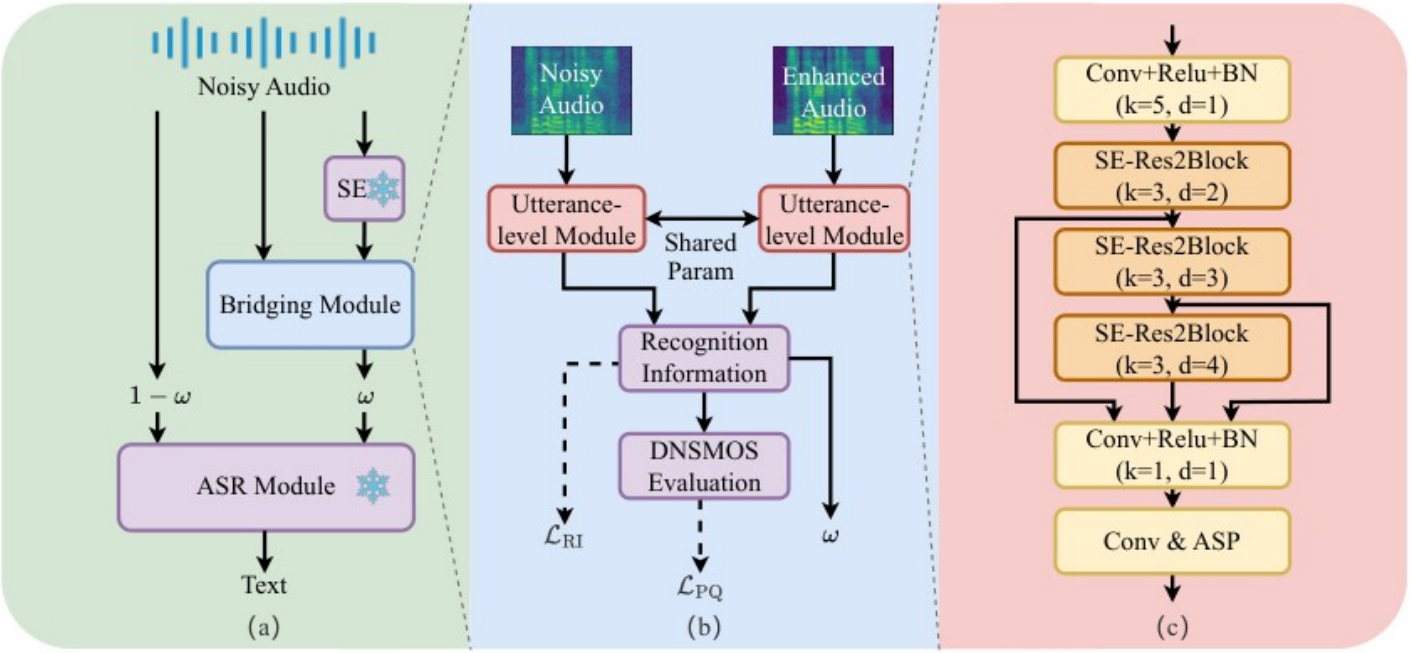
داده مرحله نهایی

نمونه‌های تخریب‌شده و بلند
زیرمجموعه تصادفی ۲۵٪ از نمونه‌های گفتار پاک

ضرایب زیان بی‌واحدند. این آزمایش هم معماری و هم برنامه آموزش بازشناس را تغییر می‌دهد

پل تطبیقی پیش از بازشناسی

پل تطبیقی (Adaptive Bridge): ترکیب آموخته‌شده صوت اصلی و بهسازی‌شده



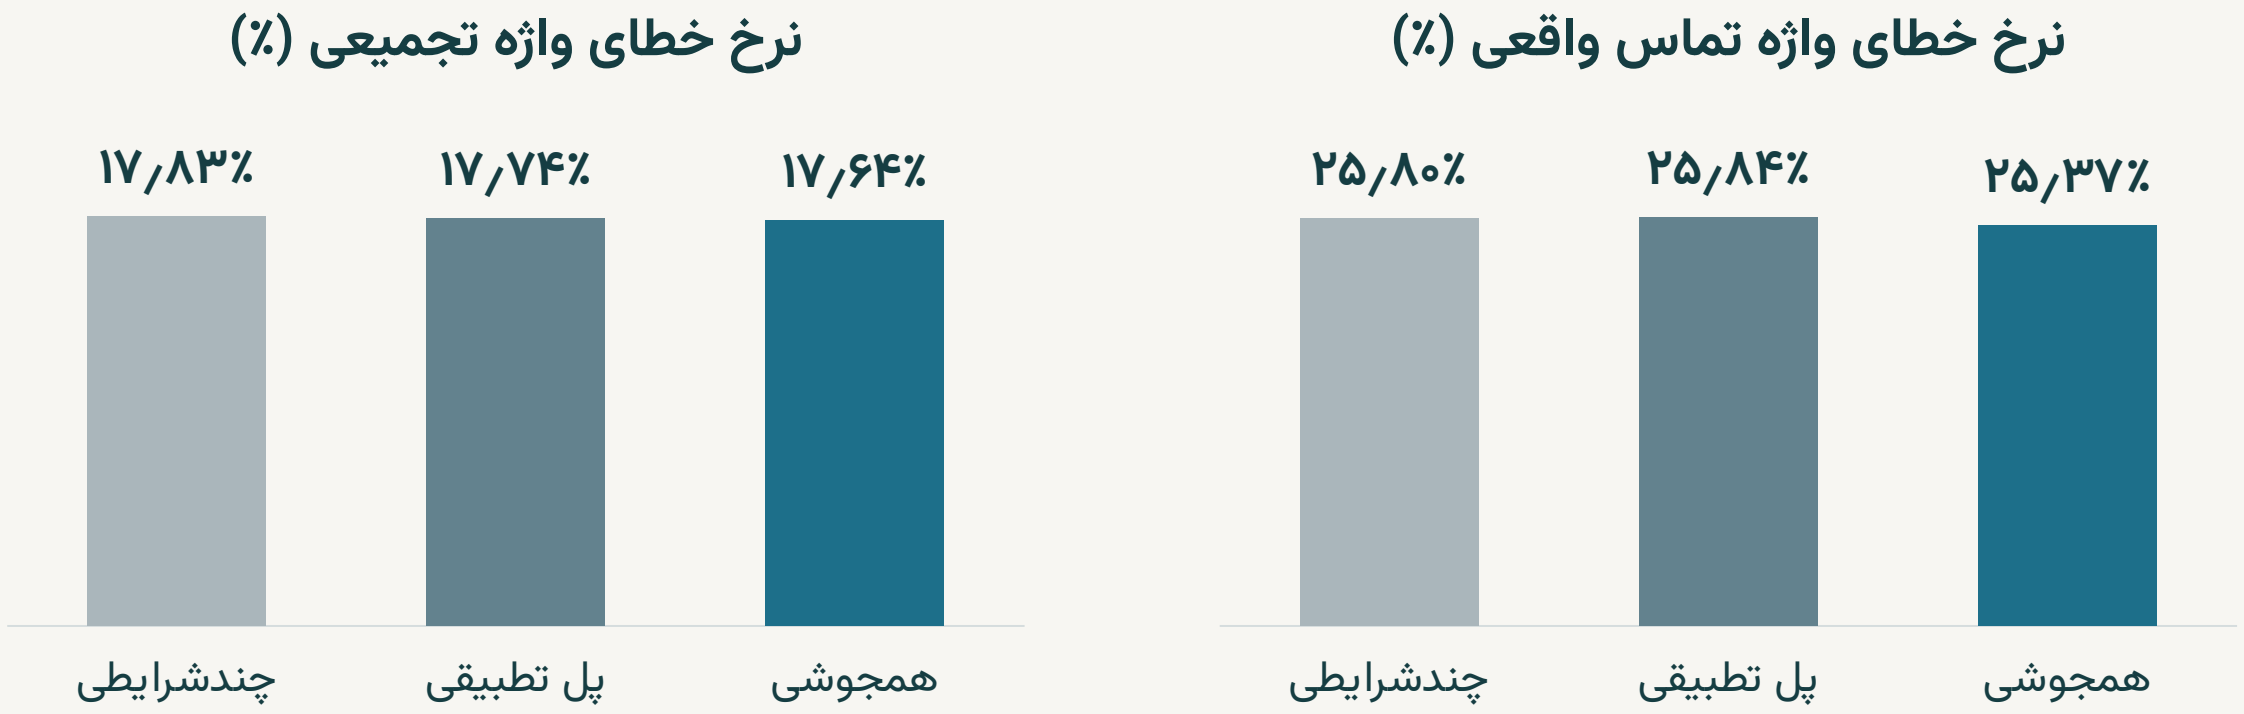
بهساز FRCRN ثابت
بازشناس ویسپر ثابت
آموزش فقط ماژول پل

یک ضریب ترکیب
برای هر گفتار

Cui et al., ICASSP 2025, Fig. 1 (CC BY 4.0)

تفاوت بهساز و برنامه آموزش، انتساب اثر به محل ادغام را محدود می‌کند

سود افزوده همجوشی و پل تطبیقی



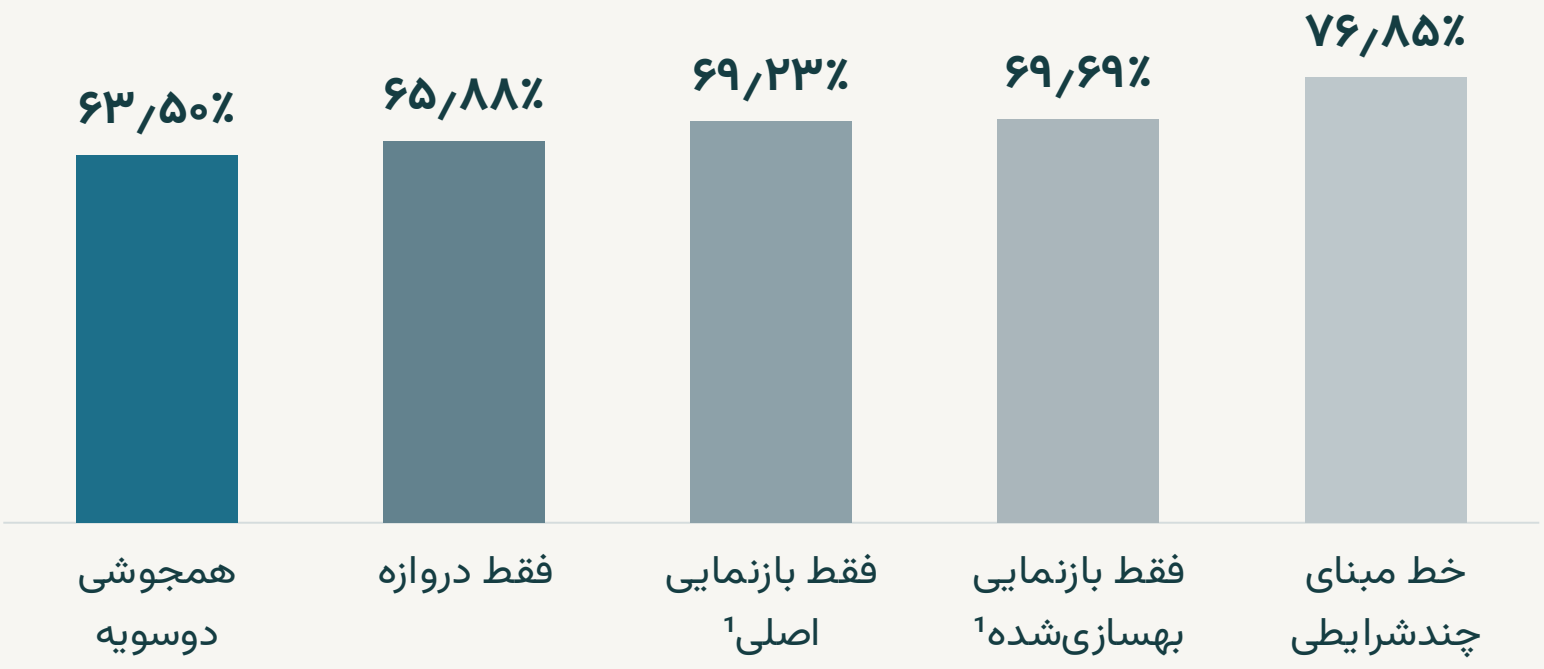
کاهش WER با همجوشی: ۰٫۱۹ واحد درصد تجمیعی و ۰٫۴۳ واحد درصد در تماس واقعی

CER تجمیعی به همین ترتیب: ۷٫۹۳٪، ۸٫۰۰٪ و ۷٫۸۵٪.

آزمایش حذفیِ دو بازنمایی و توجه متقاطع

آزمایش حذف مؤلفه (Ablation Study): بررسی اثر نماها و توجه متقاطع (Cross-attention)

نرخ خطای واژه در AGFarsdat (٪)



آزمایش مستقل ویسپر بسیار کوچک

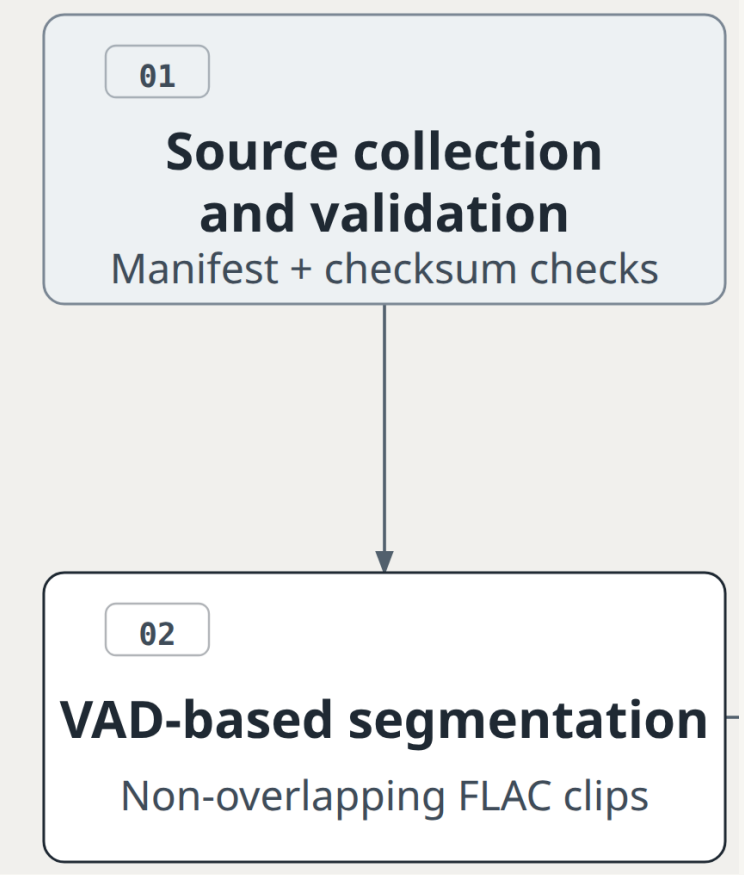
آموزش فقط با کامن‌وویس
خط مبنای چندشرایطی:
WER کامن‌وویس: ٧۴٫٩٢٪

WER کامن‌وویس چهار مدل همجوشی

۵۷٫۸۲، ۶۲٫۳۵،
۶۳٫۸۱ ،۶۴٫۱۰ درصد

[1] حذف بازنمایی در زمان استنتاج از مدل همجوشی آموزش‌دیده، نه آموزش مستقل یک مدل تک‌جریانه بودجه آموزش و تعداد پارامترهای نابرابر، تعیین سهم مستقل مؤلفه‌ها را محدود می‌کند

گردآوری و قطعه‌بندی ایران‌صدا



۳,۷۷۷ کتاب صوتی

حدود ۶,۳۰۰ ساعت صوت خام دریافت‌شده

۲۵۰ ساعت منتخب

طول هدف قطعه‌ها ۲۰ ثانیه است
بازه ترجیحی ۱۵ تا ۲۵ ثانیه، سقف سخت ۲۸ ثانیه

مجموعه گردآوری‌شده از زیرمجموعه انتخاب‌شده برای آموزش بزرگ‌تر است

رونویسی معلم، پالایش و آموزش

رونویسی معلم (Teacher Transcription)، شبه‌برچسب (Pseudo-label) و پالایش کیفیت (Quality Filtering)

۱. رونویسی معلم

03

Whisper-Medium ASR

Raw pseudo-labels per clip

۲. نرمال‌سازی فارسی

04

Deterministic Persian normalization

Persian text conventions

۳. اصلاح با Qwen

05

LLM refinement

Qwen-based text correction

۴. پالایش کیفیت

06

Quality filtering

Reject invalid audio, labels, and Qwen edits

افزودن داده پذیرفته‌شده به ترکیب کامل گفتار معمولی، بلند و تخریب‌شده

معماری ویسپر کوچک، تنظیمات اصلی و تعداد گام‌های آموزش ثابت‌اند

پالایش رونویسی و داده پذیرفته‌شده

۳۹,۴۵۴

قطعه پذیرفته‌شده برای آموزش

۲۱۸٫۵۶۴ ساعت

۴۴,۸۲۰ قطعه بررسی و ۵,۳۶۶ قطعه رد شد
۱۳۶ فایل منبع، با تفکیک در سطح کتاب

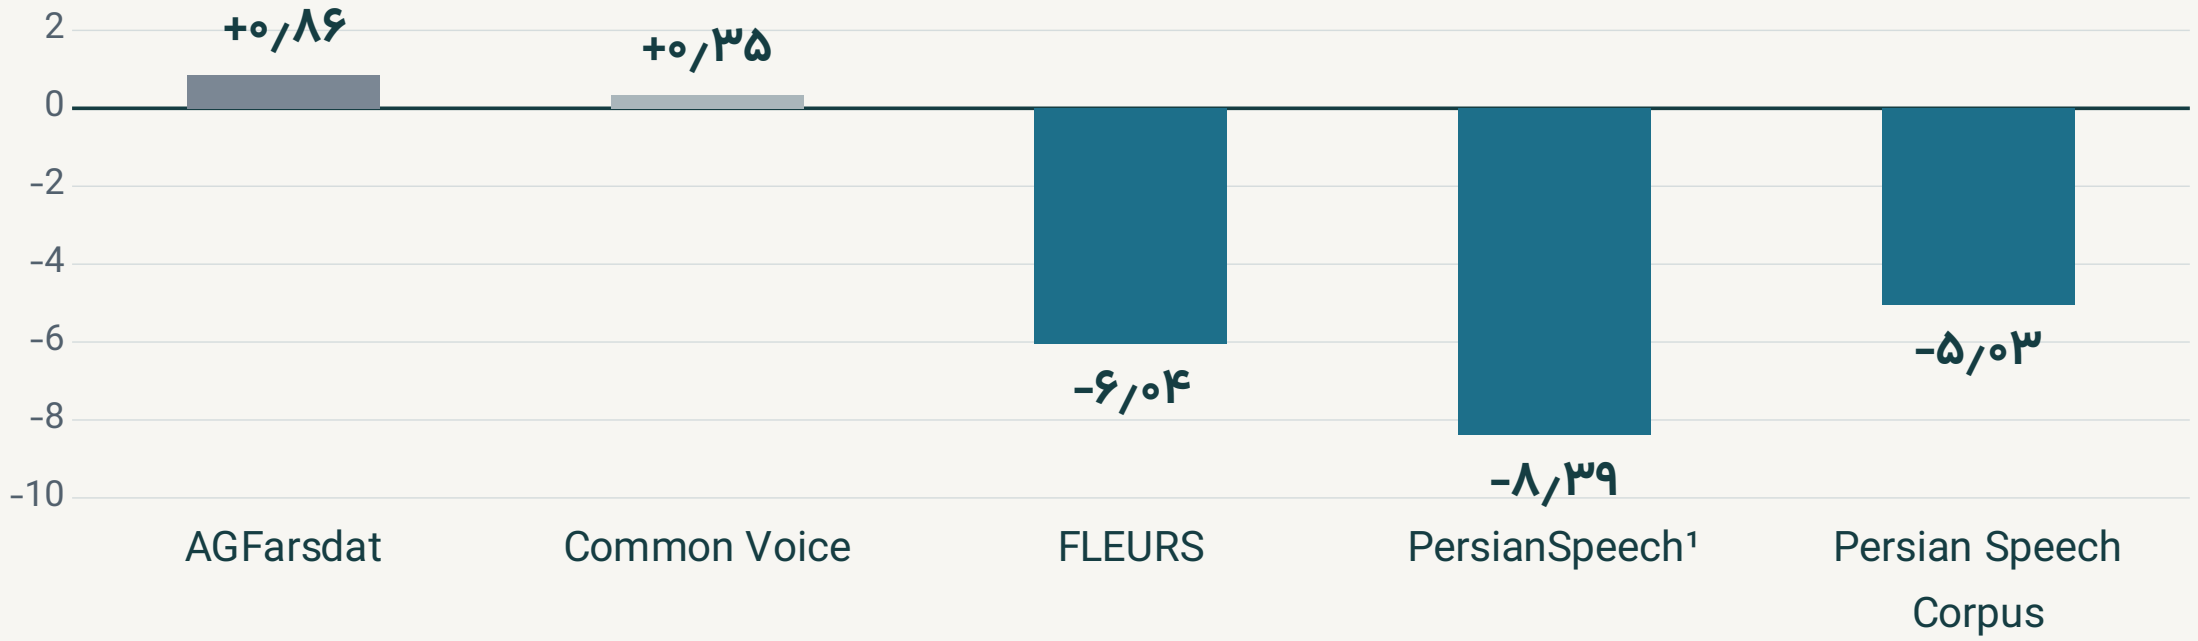
اصلاح محافظه‌کارانه با مدل زبانی Qwen

اصلاح املا، نیم‌فاصله و نشانه‌گذاری
رفع خطاهای آشکار واژگانی با کمک محتوا
حفظ اعداد و پرهیز از افزودن محتوا

ورودی فقط متن قطعه و بافت قبل و بعد آن
رد خروجی‌های نامطمئن یا دارای تغییر زیاد
ذخیره متن اولیه در کنار نسخه اصلاح‌شده

اثر ایران‌صدا به دامنه گفتار وابسته است

تغییر WER نسبت به مدل چندشرایطی (واحد درصد)



مقدار منفی یعنی بهبود. تغییر = با ایران‌صدا منهای خط مبنای چندشرایطی

تجمیعی: WER از ۱۷٫۸۳٪ به ۱۷٫۲۲٪ و CER از ۷٫۹۳٪ به ۷٫۷۰٪ رسید

نتیجه آزمایش‌های اصلی ویسپر کوچک

سامانه ویسپر کوچک	WER تجمیعی (٪)	WER تماس واقعی (٪)
معمولی	۲۳٫۲۷٪	۳۵٫۶۳٪
چندشرایطی	۱۷٫۸۳٪	۲۵٫۸۰٪
همجوشی پیشنهادی	۱۷٫۶۴٪	**۲۵٫۳۷٪**
چندشرایطی و ایران‌صدا	**۱۷٫۲۲٪**	۲۶٫۶۶٪

کمترین خطای تجمیعی: ایران‌صدا

کمترین خطای تماس واقعی: همجوشی

ویسپر متوسط: ۱۴٫۳۶٪ تجمیعی و ۲۱٫۹۹٪ تماس واقعی، با ظرفیت و آموزش متفاوت

محدودیت‌ها و آزمایش‌های بعدی

۱	سهم مستقل تخریب‌ها	اثر جداگانه نویز، کدک و افت بسته سنجیده نشده است آزمایش حذفی هر تخریب با تنظیمات آموزش یکسان
۲	اثر معماری و برنامه آموزش	معماری و برنامه آموزش هم‌زمان تغییر کرده‌اند مقایسه همجوشی با خط مبنا تحت آموزش یکسان
۳	کیفیت و تناسب داده	ممیزی انسانی متن معلم و اصلاح‌های مدل زبانی آزمایش نسبت داده و گفتار نزدیک به تماس
۴	ترکیب روش‌های پیشنهادی	همجوشی و ایران‌صدا جداگانه ارزیابی شده‌اند آزمون ترکیب آن‌ها و سنجش سود احتمالی

پوشش محدود شبیه‌ساز و خصوصی‌بودن آزمون تماس واقعی نیز دامنه شواهد را محدود می‌کنند

نتیجه‌گیری پژوهش

- آموزش چندشرایطی: کاهش WER تماس واقعی از ۳۵٫۶۳٪ به ۲۵٫۸۰٪، برابر ۹٫۸۳ واحد درصد.
- همجوشی دوجریانه: WER تماس واقعی ۲۵٫۳۷٪، با سود افزوده ۰٫۴۳ واحد درصد.
- ایران‌صدا، WER تجمیعی را از ۱۷٫۸۳٪ به ۱۷٫۲۲٪ کاهش داد؛ WER تماس واقعی به ۲۶٫۶۶٪ افزایش یافت.
- تناسب داده با کانال هدف، بیشترین سود را در این آزمایش‌ها داشت؛ بهبود تجمیعی به همه دامنه‌ها منتقل نشد.

اختلاف کوچک همجوشی، بدون تکرار آزمایش و آزمون معناداری، برتری آماری را ثابت نمی‌کند

نوآوری‌ها و دستاوردهای پژوهش

- طراحی خط لوله بازتولیدپذیر ساخت جفت‌های پاک و مخابراتی، با ثبت بذر و فراداده هر نمونه.
- ارزیابی انتقال آموزش چندشرایطی به تماس واقعی فارسی و فراهم‌کردن خط مبنایی مقاوم برای مقایسه روش‌ها.
- پیاده‌سازی همجوشی دوجریانه با بهساز باقیمانده، رمزگذار مشترک، توجه متقاطع دوسویه و دروازه زمان–ویژگی.
- ساخت خط لوله ایران‌صدا برای قطعه‌بندی، تولید و اصلاح شبه‌برچسب‌ها و پالایش کیفیت؛ ارزیابی سود آن به تفکیک دامنه.

سپاسگزارم؛ پرسش‌ها

مراجع

[1] P. Peso Parada et al., “pMCT: Patched Multi-Condition Training for Robust Speech Recognition,” Interspeech, pp. 3779–3783, 2022.

doi: 10.21437/Interspeech.2022-117

[2] D. Liu et al., “Towards Pretraining Robust ASR Foundation Model with Acoustic-Aware Data Augmentation,” arXiv:2505.20606, 2025.

doi: 10.48550/arXiv.2505.20606

[3] T. Niu et al., “Parameter-Efficient Adaptation with Multi-Channel Adversarial Training for Far-Field Speech Recognition,” EURASIP JASMP, 2025.

doi: 10.1186/s13636-025-00406-5

[4] B. Namdarzadeh et al., “Fine-tuning Whisper with Spontaneous Persian Speech (SPS),” SIGUL, pp. 263–269, 2026.

doi: 10.63317/2ca2yoj8fzgd

[5] A. Amirivojdan et al., “Neyshekar: An Open Persian Read-Speech Corpus for Automatic Speech Recognition,” arXiv:2609.14542, 2026.

doi: 10.48550/arXiv.2609.14542

[6] K. S. Bhogale et al., “Empowering Low-Resource Language ASR via Large-Scale Pseudo Labeling,” Interspeech, pp. 2519–2523, 2024.

doi: 10.21437/Interspeech.2024-2396

[7] S. Bandarupalli et al., “Efficient ASR for Low-Resource Languages: Leveraging Cross-Lingual Unlabeled Data,” Findings of IJCNLP-AACL, pp. 1611–1617, 2025.

doi: 10.18653/v1/2025.findings-ijcnlp.99

[8] J. Baik et al., “DASH: Dual-View Self-Distillation with Multi-Layer Hidden Representations for Robust Speech Recognition,” Interspeech, pp. 3116–3121, 2026.

ISCA Archive, Interspeech 2026

مراجع

[9] Y. Hu et al., “Listen Again and Choose the Right Answer: A New Paradigm for Automatic Speech Recognition with Large Language Models,” Findings of ACL, pp. 666–679, 2024.

doi: 10.18653/v1/2024.findings-acl.37

[10] T. Udagawa et al., “Robust ASR Error Correction with Conservative Data Filtering,” EMNLP Industry, pp. 256–266, 2024.

doi: 10.18653/v1/2024.emnlp-industry.20

[11] M. A. Shah et al., “Speech Robust Bench: A Robustness Benchmark for Speech Recognition,” ICLR, pp. 38625–38651, 2025.

ICLR 2025 proceedings

[12] K. Saijo et al., “Interspeech 2025 URGENT Speech Enhancement Challenge,” Interspeech, pp. 858–862, 2025.

doi: 10.21437/Interspeech.2025-1363

[13] N. Sedghiyeh et al., “PSRB: A Comprehensive Benchmark for Evaluating Persian ASR Systems,” arXiv:2505.21230, 2025.

doi: 10.48550/arXiv.2505.21230

[14] R. Nasretdinov et al., “Robust Speech Recognition with Schrödinger Bridge-Based Speech Enhancement,” ICASSP, pp. 1–5, 2025.

doi: 10.1109/ICASSP49660.2025.10890638

[15] Y. Yang et al., “Towards Decoupling Frontend Enhancement and Backend Recognition in Monaural Robust ASR,” Comput. Speech Lang., vol. 95, Art. 101821, 2026.

doi: 10.1016/j.csl.2025.101821

[16] Y. Dissen et al., “A Front-End Adaptation Network for Improving Speech Recognition Performance in Packet Loss and Noisy Environments,” IEEE TASLPRO, vol. 33, pp. 2175–2188, 2025.

doi: 10.1109/TASLPRO.2025.3574840

مراجع

[17] H. Sato et al., “Generic Speech Enhancement with Self-Supervised Representation Space Loss,” Front. Signal Process., vol. 5, Art. 1587969, 2025.

doi: 10.3389/frsip.2025.1587969

[18] D. Yang et al., “FAT-HuBERT: Front-End Adaptive Training of Hidden-Unit BERT for Distortion-Invariant Robust Speech Recognition,” ASRU, pp. 1–8, 2023.

doi: 10.1109/ASRU57964.2023.10389685

[19] Y. Hu et al., “Wav2code: Restore Clean Speech Representations via Codebook Lookup for Noise-Robust ASR,” IEEE/ACM TASLP, vol. 32, pp. 1145–1156, 2024.

doi: 10.1109/TASLP.2023.3332545

[20] K. Wang et al., “Bridging the Gap: Integrating Pre-Trained Speech Enhancement and Recognition Models for Robust Speech Recognition,” EUSIPCO, pp. 426–430, 2024.

doi: 10.23919/EUSIPCO63174.2024.10715447

[21] Z. Cui et al., “Reducing the Gap Between Pretrained Speech Enhancement and Recognition Models Using a Real Speech-Trained Bridging Module,” ICASSP, pp. 1–5, 2025.

doi: 10.1109/ICASSP49660.2025.10889737

[22] H. Li et al., “Training-Free Intelligibility-Guided Observation Addition for Noisy ASR,” Interspeech, pp. 3138–3143, 2026.

doi: 10.21437/Interspeech.2026-1096

[23] M. Qu et al., “Mitigating Over-Suppression in Speech Enhancement via Inference-Time Rethink-and-Refine Correction Module,” IEEE MLSP, 2026.

doi: 10.48550/arXiv.2608.07781

مطالب تکمیلی

جزئیات داده‌ها و نتایج پژوهش

مقایسه مدل‌ها روی زیرمجموعه مشترک

مدل	WER تجمیعی	CER تجمیعی	WER تماس واقعی
Chirp 3	۱۶٫۴۴٪	۵٫۱۴٪	۲۲٫۹۴٪
GPT-4o Transcribe	۱۸٫۵۵٪	۶٫۹۴٪	۴۸٫۶۲٪
کوچک: چندشرایطی و ایران‌صدا	۲۰٫۷۲٪	۱۰٫۷۲٪	۲۶٫۶۱٪
همجوشی دوجریانه	۲۱٫۷۲٪	۱۰٫۹۷٪	۲۵٫۳۱٪
ویسپر متوسط	۲۳٫۱۳٪	۱۱٫۲۴٪	۲۴٫۷۷٪
Voxtral Small 24B	۲۶٫۹۲٪	۱۰٫۷۵٪	۴۵٫۸۷٪
Qwen3-ASR 1.7B	۳۶٫۶۶٪	۱۵٫۶۸٪	۶۳٫۳۰٪
Grok STT 1.0	۴۰٫۸۸٪	۲۳٫۶۸٪	۶۷٫۸۹٪
Nemotron 3.5 ASR 0.6B	۹۸٫۷۰٪	۸۰٫۸۶٪	۱۰۴٫۵۹٪

۱۰۰ نمونه ثابت، ۲۰ نمونه از هر مجموعه. این مقایسه جایگزین ارزیابی کامل نیست

نرخ خطای واژه به تفکیک مجموعه

سامانه	AGFarsdat	کامن‌وویس ۲۵	فلورز	پرشین‌اسپیچ[1]	پیکره گفتار فارسی
معمولی	۳۵٫۶۳٪	۱۱٫۵۲٪	۲۱٫۰۵٪	۳۴٫۵۳٪	۳۰٫۱۷٪
داده‌افزایی نویزی	۳۲٫۶۷٪	۷٫۸۶٪	۱۹٫۲۶٪	۳۳٫۵۷٪	۳۰٫۴۷٪
pMCT	۳۰٫۰۱٪	۷٫۲۵٪	۲۰٫۲۳٪	۳۱٫۶۵٪	۳۰٫۵۰٪
چندشرایطی	۲۵٫۸۰٪	۷٫۸۴٪	۱۹٫۸۲٪	۳۵٫۲۵٪	۳۰٫۹۰٪
همجوشی دوجریانه	۲۵٫۳۷٪	۷٫۵۳٪	۱۹٫۶۷٪	۳۱٫۸۱٪	۳۳٫۸۲٪
پل تطبیقی	۲۵٫۸۴٪	۷٫۶۳٪	۱۹٫۷۳٪	۳۵٫۰۹٪	۳۲٫۳۲٪
ویسپر متوسط	**۲۱٫۹۹٪**	**۳٫۸۴٪**	۱۷٫۱۴٪	۳۱٫۶۵٪	۳۱٫۱۷٪
چندشرایطی و ایران‌صدا	۲۶٫۶۶٪	۸٫۱۹٪	**۱۳٫۷۸٪**	**۲۶٫۸۶٪**	**۲۵٫۸۷٪**

همه اعداد WER و درصد هستند. [1] فقط ۲۴ نمونه. تعداد واجدشرایط پیکره گفتار فارسی تغییر می‌کند

آزمایش کامل مؤلفه‌ها در ویسپر بسیار کوچک

پیکربندی	Common Voice WER	Common Voice CER	AGFarsdat WER	AGFarsdat CER
خط مبنای چندشرایطی	۷۴٫۹۲٪	۳۸٫۰۳٪	۷۶٫۸۵٪	۳۵٫۰۴٪
همجوشی فقط دروازه‌ای	۶۲٫۳۵٪	۳۲٫۸۷٪	۶۵٫۸۸٪	۲۸٫۴۲٪
توجه متقاطع باقیمانده	۶۰٫۲۶٪	۳۱٫۹۰٪	۶۵٫۴۸٪	۲۸٫۳۵٪
فقط نمای اصلی[1]	۶۴٫۱۰٪	۳۳٫۲۱٪	۶۹٫۲۳٪	۳۰٫۳۹٪
فقط نمای بهسازی‌شده[1]	۶۳٫۸۱٪	۳۳٫۰۵٪	۶۹٫۶۹٪	۳۰٫۷۳٪
همجوشی دوسویه	**۵۷٫۸۲٪**	**۳۰٫۵۷٪**	**۶۳٫۵۰٪**	**۲۷٫۰۲٪**
پل: فقط PQ	۷۴٫۴۸٪	۳۷٫۸۱٪	۷۶٫۶۳٪	۳۴٫۸۳٪
پل: فقط صوت بهسازی‌شده	۷۵٫۹۰٪	۳۸٫۷۹٪	۷۷٫۶۷٪	۳۵٫۵۳٪
پل: PQ + RI	۷۴٫۴۰٪	۳۷٫۸۱٪	۷۶٫۸۱٪	۳۴٫۹۴٪

[1] حذف مسیر در استنتاج. آموزش فقط با کامن‌وویس است. بودجه آموزش و ظرفیت گونه‌ها برابر نیست

توزیع نمایه‌های تخریب مخابراتی

نمایه	سهم انتخاب	احتمال افزودن نویز	احتمال اختلال شبکه
telephone_clean	۲۵٪	۰٪	۱۰٪
telephone_noisy	۳۰٪	۷۰٪	۲۰٪
voip_lossy	۲۵٪	۳۰٪	۸۰٪
mobile_wideband	۲۰٪	۴۵٪	۳۰٪

احتمال کلی افزودن نویز: ۳۷٫۵٪

احتمال کلی اختلال شبکه: ۳۴٫۵٪

ابتدا نمایه انتخاب می‌شود، سپس احتمال‌های همان نمایه روی نمونه اعمال می‌شوند

وزن‌ها طراحی آموزشی‌اند. درصدها احتمال نمونه‌برداری‌اند و شمارش واقعی داده نیستند

توزیع کدک در هر نمایه و در کل داده

کدک	تلفن بدون نویز	تلفن نویزی	VoIP با افت بسته	همراه پهن‌باند	سهم کل
G.711 A-law	۳۵٪	۳۵٪	۰٪	۰٪	۱۹٫۲۵٪
G.711 μ-law	۲۰٪	۱۵٪	۰٪	۰٪	۹٫۵۰٪
GSM	۲۰٪	۲۰٪	۰٪	۰٪	۱۱٫۰۰٪
AMR-NB (12.2 kb/s)	۲۵٪	۳۰٪	۰٪	۰٪	۱۵٫۲۵٪
AMR-WB (12.65 kb/s)	۰٪	۰٪	۰٪	۵۵٪	۱۱٫۰۰٪
Opus WB	۰٪	۰٪	۷۰٪	۳۰٪	۲۳٫۵۰٪
Opus NB	۰٪	۰٪	۳۰٪	۰٪	۷٫۵۰٪
pass_through	۰٪	۰٪	۰٪	۱۵٪	۳٫۰۰٪

سهم کل کدک = مجموعِ «سهم نمایه × احتمال کدک در همان نمایه»

جمع هر ستون ۱۰۰٪ است. انتخاب نمایه، توزیع کدک سراسری را بازنویسی می‌کند

توزیع نویز، SNR و تغییر بهره

بازه SNR (dB)	احتمال در نمونه نویزی	سهم از کل نمونه‌ها
-5 to 0	۲۵٪	۹٫۳۷۵٪
0 to 5	۲۵٪	۹٫۳۷۵٪
5 to 10	۲۵٪	۹٫۳۷۵٪
10 to 15	۲۵٪	۹٫۳۷۵٪

انتخاب بازه هم‌احتمال است. SNR داخل بازه، توزیع یکنواخت پیوسته دارد

در نمونه‌های نویزی: یک فایل ۹۰٪، دو فایل ۱۰٪ با انتخاب مستقل از DEMAND

از کل داده: بدون نویز ۶۲٫۵٪، یک فایل ۳۳٫۷۵٪، دو فایل ۳٫۷۵٪

انتخاب فایل در فهرست یکنواخت است. سهم هر محیط به تعداد فایل‌های آن بستگی دارد

بهره روی کل مخلوط: یکنواخت از ۶- تا ۶+ دسی‌بل، بدون تغییر SNR

درصدهای نویز، وجود فهرست معتبر DEMAND را فرض می‌کنند

پهنای‌باند کانال و پارامترهای Opus

مسیر	نرخ کانال	بازه فرکانسی (Hz)	سهم کل
باریک‌باند	8 kHz	300–3400	۶۴٪
پهن‌باند	16 kHz	50–7000	۳۶٪

عبور مستقیم: ۳٪ کل داده، با انتخاب ۵۰٪ باریک‌باند و ۵۰٪ پهن‌باند

نمایه و کدک	نرخ بیت (kb/s)	طول قاب (ms)
voip_lossy: Opus WB	16 / 24 / 32	20 / 40 / 60
voip_lossy: Opus NB	12 / 16	20 / 40
mobile_wideband: Opus WB	16 / 24 / 32	20 / 40

گزینه‌های هر خانه هم‌احتمال‌اند. نرخ بیت و طول قاب مستقل انتخاب می‌شوند

خروجی همه مسیرها: تک‌کاناله و ۱۶ کیلوهرتز، با حفظ محدودیت پهنای‌باند

توزیع شدت افت و مدل اختلال شبکه

بازه نرخ افت	احتمال پس از فعال‌شدن	سهم از کل نمونه‌ها
0.3% to 2%	۱/۳	۱۱٫۵٪
2% to 5%	۱/۳	۱۱٫۵٪
5% to 10%	۱/۳	۱۱٫۵٪

نرخ افت داخل بازه یکنواخت است. طول متوسط جهش از ۱ تا ۵ قاب انتخاب می‌شود

مدل دوحالته خوب/بد با شروع از توزیع پایا، برای ایجاد افت‌های متوالی

Opus: حذف بسته پیش از رمزگشایی و پنهان‌سازی افت با PLC

سایر مسیرها: صفرکردن قاب‌های موج پس از رمزگشایی، با قاب ۲۰ میلی‌ثانیه

سهم موردانتظار از کل: Opus با PLC برابر ۲۱٫۸٪، حذف موج برابر ۱۲٫۷٪

نرخ افتِ هدف با نرخ افتِ مشاهده‌شده در قطعه‌های کوتاه یکسان نیست

ساخت جفت‌های هم‌تراز و ثبت فراداده

جزء خط لوله	تنظیم اجرا
تولید داده مخابراتی	**۲ گونه برای هر قطعه در train و dev**
اجرای رمزگذاری و رمزگشایی	**ffmpeg، یا Opus بومی در شاخه PLC**
هم‌ترازی زمانی	**هم‌بستگی متقاطع و جبران تأخیر کدک**
هدف پاک	**همان محدودیت پهنای‌باند، طول و نرخ نمونه**
کنترل دامنه جفت	**ضریب مشترک و سقف دامنه ۰٫۹۹ نسبت به تمام‌مقیاس (بی‌واحد)**
کلیپینگ مصنوعی و AGC	**غیرفعال در پیکربندی حاضر**

هم‌ترازی زمانی (Time Alignment) و فراداده (Metadata) برای بازتولید آزمایش

JSONL: نمایه، بذر، کدک، SNR، مسیر کانال، افت واقعی و ضریب نرمال‌سازی

نویز، بهره، فیلتر و کدک به این شبیه‌سازی تعلق دارند. پژواک و نوسان تأخیر مدل نشده‌اند

اندازه پیکره‌ها و تنظیمات خط مبنا

پیکره پایه	آموزش (نمونه)	اعتبارسنجی (نمونه)	نقش در آموزش
کامن‌وویس فارسی ۲۵	۲۹۹۴۳۰	۱۰۰۰۶	گفتار عمومی و تولید تخریب
فارس‌اسپان (محدود)	۶۰۰۶۷۲	۶۰۴۴	گفتار بداهه فارسی
فلورز فارسی	۳۰۱۹	۳۶۲	تنوع دامنه

ویسپر کوچک تک‌جریانه

یک دوره، نرخ یادگیری ۰٫۰۰۰۰۱ (بی‌واحد)
دسته ۴ نمونه، انباشت ۸ گام: ۳۲ نمونه

جزئیات آزمون AGFarsdat

۵۸۵ گوینده و ۴۹٫۹ ساعت
صوت منبع: تک‌کاناله، ۸ کیلوهرتز، ۱۶ بیت

واحد شمارش جدول: نمونه گفتار (Utterance). گونه‌های بلند، تخریب‌شده و ایران‌صدا در جدول نیستند

آموزش چندشرایطی در فست کانفورمر

مجموعه آزمون	WER معمولی	CER معمولی	WER چندشرایطی	CER چندشرایطی
تجمیعی	۲۲٫۷۳٪	۱۴٫۷۹٪	۲۱٫۸۱٪	۱۴٫۴۵٪
AGFarsdat	۳۱٫۰۷٪	۱۴٫۸۱٪	۳۰٫۴۸٪	۱۴٫۰۹٪
کامن‌وویس فارسی ۲۵	۱۱٫۶۸٪	۱۶٫۴۶٪	۱۰٫۰۱٪	۱۶٫۱۰٪
فلورز فارسی	۲۹٫۲۲٪	۹٫۹۴٪	۲۹٫۴۰٪	۱۰٫۲۲٪
پرشین‌اسپیچ	۳۰٫۷۰٪	۱۳٫۵۰٪	۳۱٫۴۱٪	۱۳٫۵۶٪
پیکره گفتار فارسی	۳۳٫۶۹٪	۱۲٫۲۲٪	۳۳٫۵۹٪	۱۲٫۶۸٪

کاهش WER تجمیعی: ۰٫۹۲ واحد درصد، حدود ۴٪ کاهش نسبی

مقایسه درون فست کانفورمر است. تفاوت پیش‌آموزش و آموزش، انتساب فاصله با ویسپر را محدود می‌کند

پرامپت اصلاح رونویسی با Qwen

cyankiwi/Qwen3.6-27B-AWQ-INT4 · temperature = 0 (unitless)

Refine one Persian ASR segment conservatively. Modify only the TARGET WHISPER TEXT.
Allowed corrections:
- Persian orthography and spelling
- spacing and نیم‌فاصله
- punctuation when clearly justified
- obvious ASR word substitutions when the intended spoken word is strongly supported by the target and context
Rules:
- Preserve the meaning and wording of the spoken target as closely as possible.
- Use surrounding context only to disambiguate the target.
- Never copy words or phrases from the context into the target unless they clearly correct an ASR error already present in the target.
- Never complete an incomplete phrase at a segment boundary.
- Never add, infer, summarize, or rewrite speech that is not present in the target.
- Do not remove valid spoken words merely to improve fluency.

Rules (continued):
- Preserve every numeric token exactly as written, including digits, signs, separators, and formatting.
- When a correction is not sufficiently certain, keep the original text and set uncertain=true.
- Set uncertain=false only when all applied corrections are high-confidence.
- Return only the required JSON object with no explanation or Markdown.
[AUDIOBOOK TITLE]
<audiobook title or (omitted)>
[AUDIOBOOK DESCRIPTION]
<audiobook description or (omitted)>
[REFINED PRECEDING CONTEXT]
<up to three previously accepted refined segments or (none)>
[TARGET WHISPER TEXT]
<normalized target transcription>
[FOLLOWING WHISPER CONTEXT]
<up to three following normalized Whisper segments or (none)>