دانشگاه صنعتی شریف

دانشکده مهندسی کامپیوتر

بازشناسی مقاوم گفتار در زبان فارسی

پویا فلاح سیچانی

استاد راهنما: دکتر حسین صامتی

دفاع پایان‌نامه کارشناسی ارشد

شکاف میان گفتار آموزشی و تماس واقعی

گفتار در دسترس

پیکره‌های عمومیِ فارسی
قطعه‌های عمدتاً کوتاه
سبک‌ها و شرایط ضبط متنوع

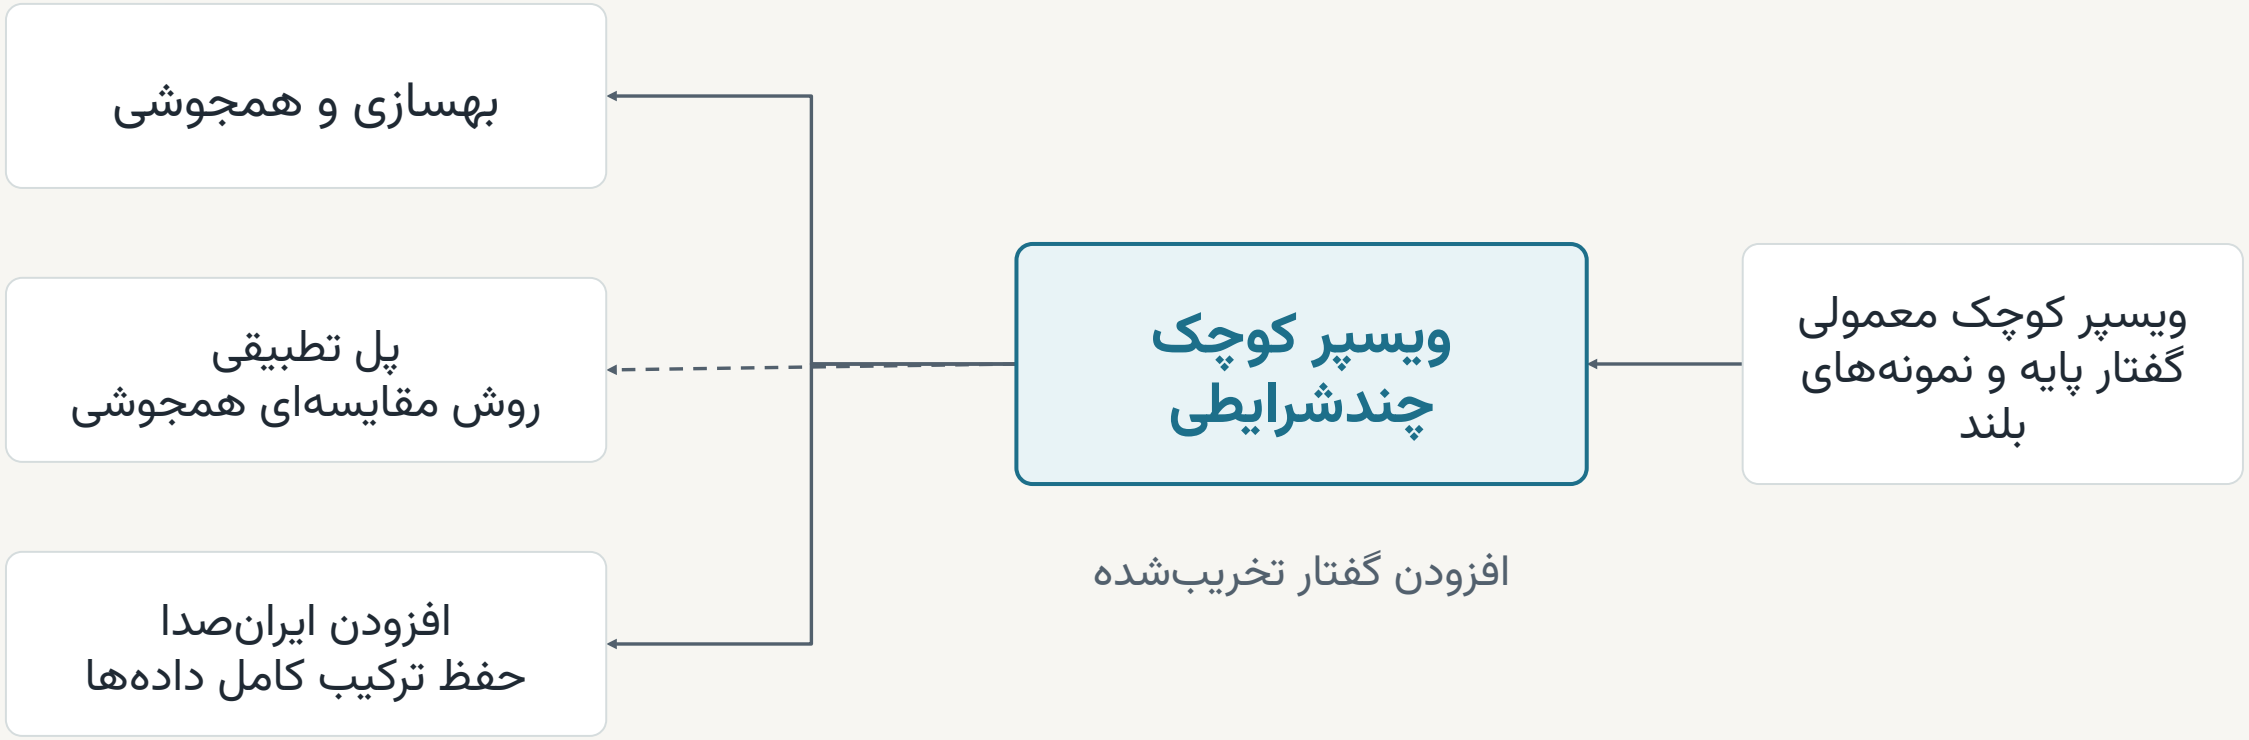
شرایط تماس

نویز و پهنای‌باند محدود
اعوجاج کدک و افت بسته
تلفن و تماس اینترنتی

هدف: کاهش خطای تماس واقعی با داده‌های موجود

گردآوری تماس رونویسی‌شده پرهزینه و حساس به حریم خصوصی است

ساختار آزمایش‌ها و خط مبنا



همجوشی و ایران‌صدا دو مسیر مستقل‌اند. سامانه ترکیبی آن‌ها ارزیابی نشده است

داده‌های آموزش

گفتار پایه فارسی

Common Voice Persian 25
FarsSpon (زیرمجموعه محدود)
FLEURS Persian

صوت تک‌کاناله ۱۶ کیلوهرتزی و نرمال‌سازی مشترک متن فارسی

۲ تا ۴

قطعه برای ساخت هر نمونه بلند

اتصال درون همان بخش داده
بیش از ۵ و حداکثر ۲۰ ثانیه
حضور در خط مبنای معمولی

ارزیابی روی تماس واقعی و گفتار عمومی

۱۰,۰۴۴

نمونه تماس واقعی در AGFarsdat

تلفن و تماس اینترنتی
مستقل از آموزش و انتخاب مدل

آزمون‌های گفتار عمومی

Common Voice Persian 25
FLEURS Persian
PersianSpeech
Persian Speech Corpus

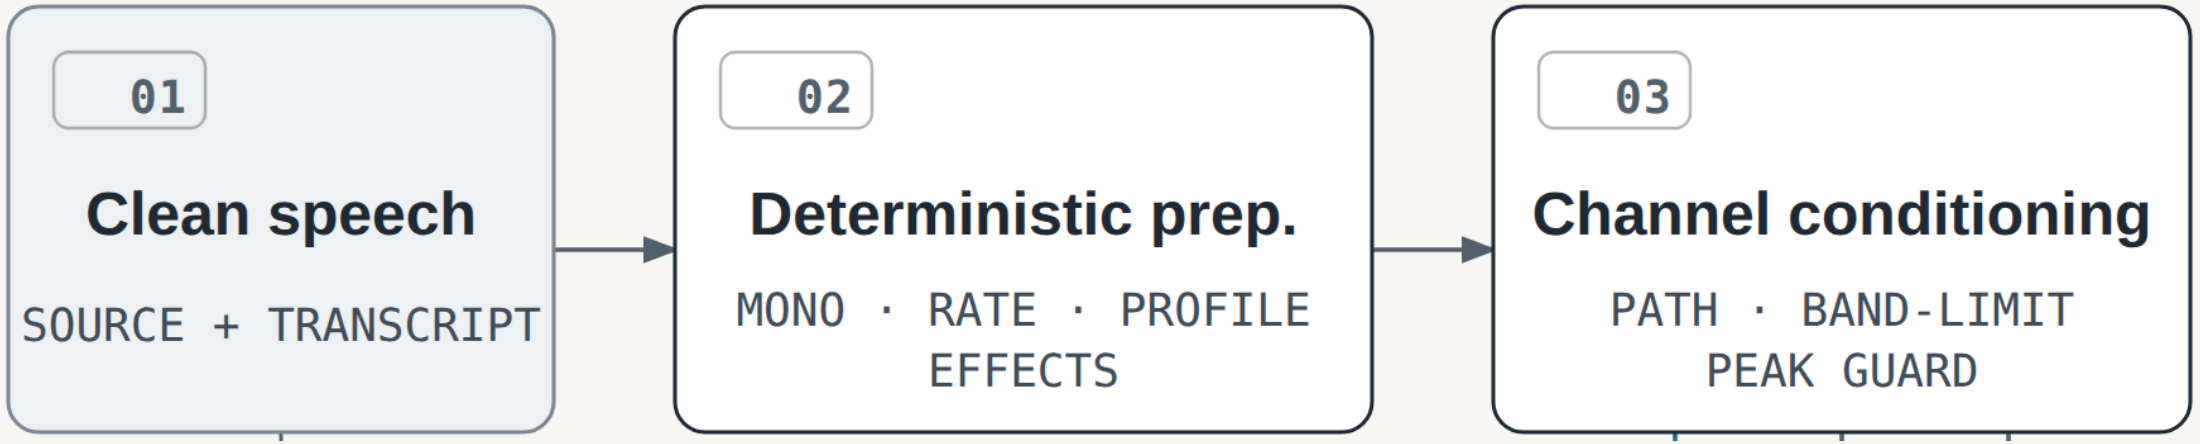
نرخ خطای واژه

$$WER = (S + D + I) / N$$

CER بر پایه نویسه است. تجمیع با جمع شمارش خطاها و واحدهای مرجع انجام می‌شود
رمزگشایی حریصانه مشترک است. PersianSpeech فقط ۲۴ نمونه دارد و واجدشرایط‌بودن کمی تغییر می‌کند

داده‌افزایی مخابراتیِ بازتولیدپذیر

ساخت جفت‌های پاک و تخریب‌شده با رونویسی مشترک



نویز و تغییر بهره

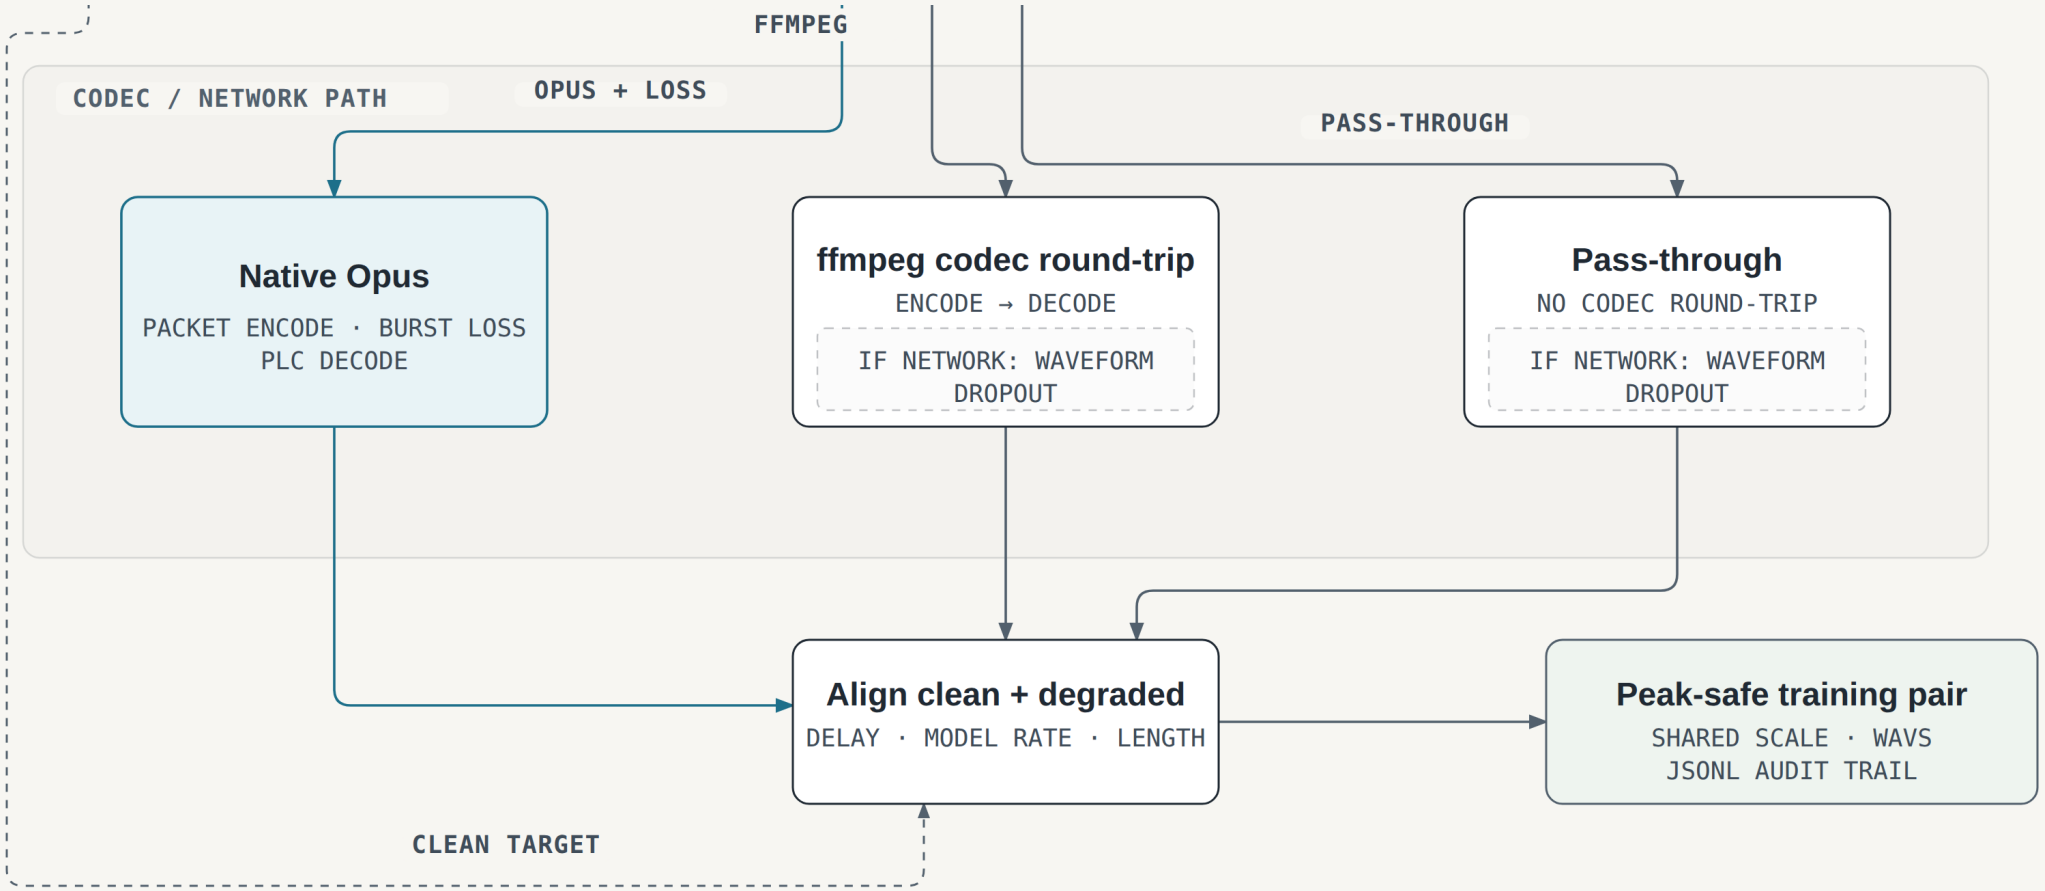
DEMAND SNR: -5 … 15 dB Gain: ±6 dB

نمایه‌های تلفن و تماس اینترنتی

ثبت بذر تصادفی و فراداده هر جفت

وزن نمایه‌ها یک توزیع طراحی‌شده است و از آمار اپراتور به دست نیامده است

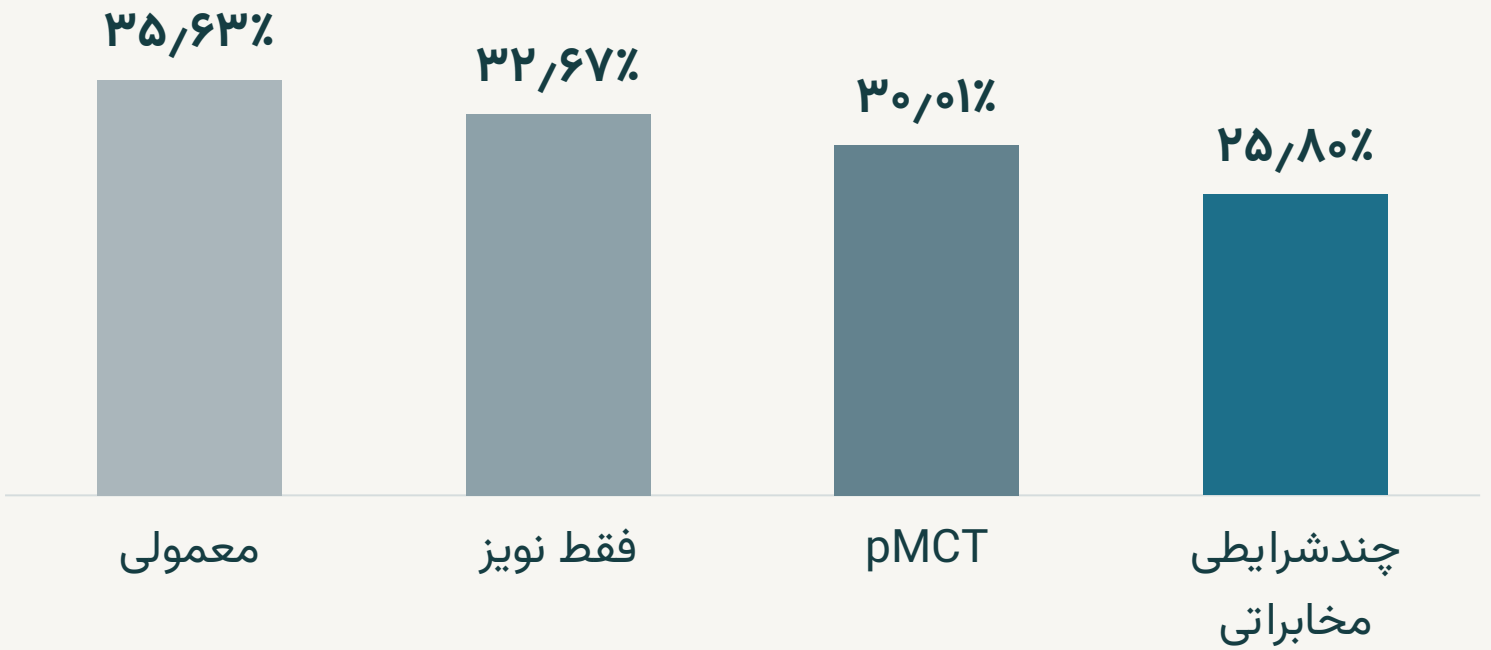
مسیرهای کدک و جفت‌های هم‌تراز



AMR-WB، AMR-NB، GSM، G.711 و Opus. هدف پاک، پهنای‌باند متناظر با کانال را حفظ می‌کند
Opus بومی افت بسته و پنهان‌سازی خطا را مدل می‌کند. در مسیرهای دیگر، حذف موج یک تقریب است

انتقال بهبود به تماس‌های واقعی

نرخ خطای واژه در AGFarsdat



۹٫۸۳

واحد درصد کاهش خطا در تماس‌های واقعی

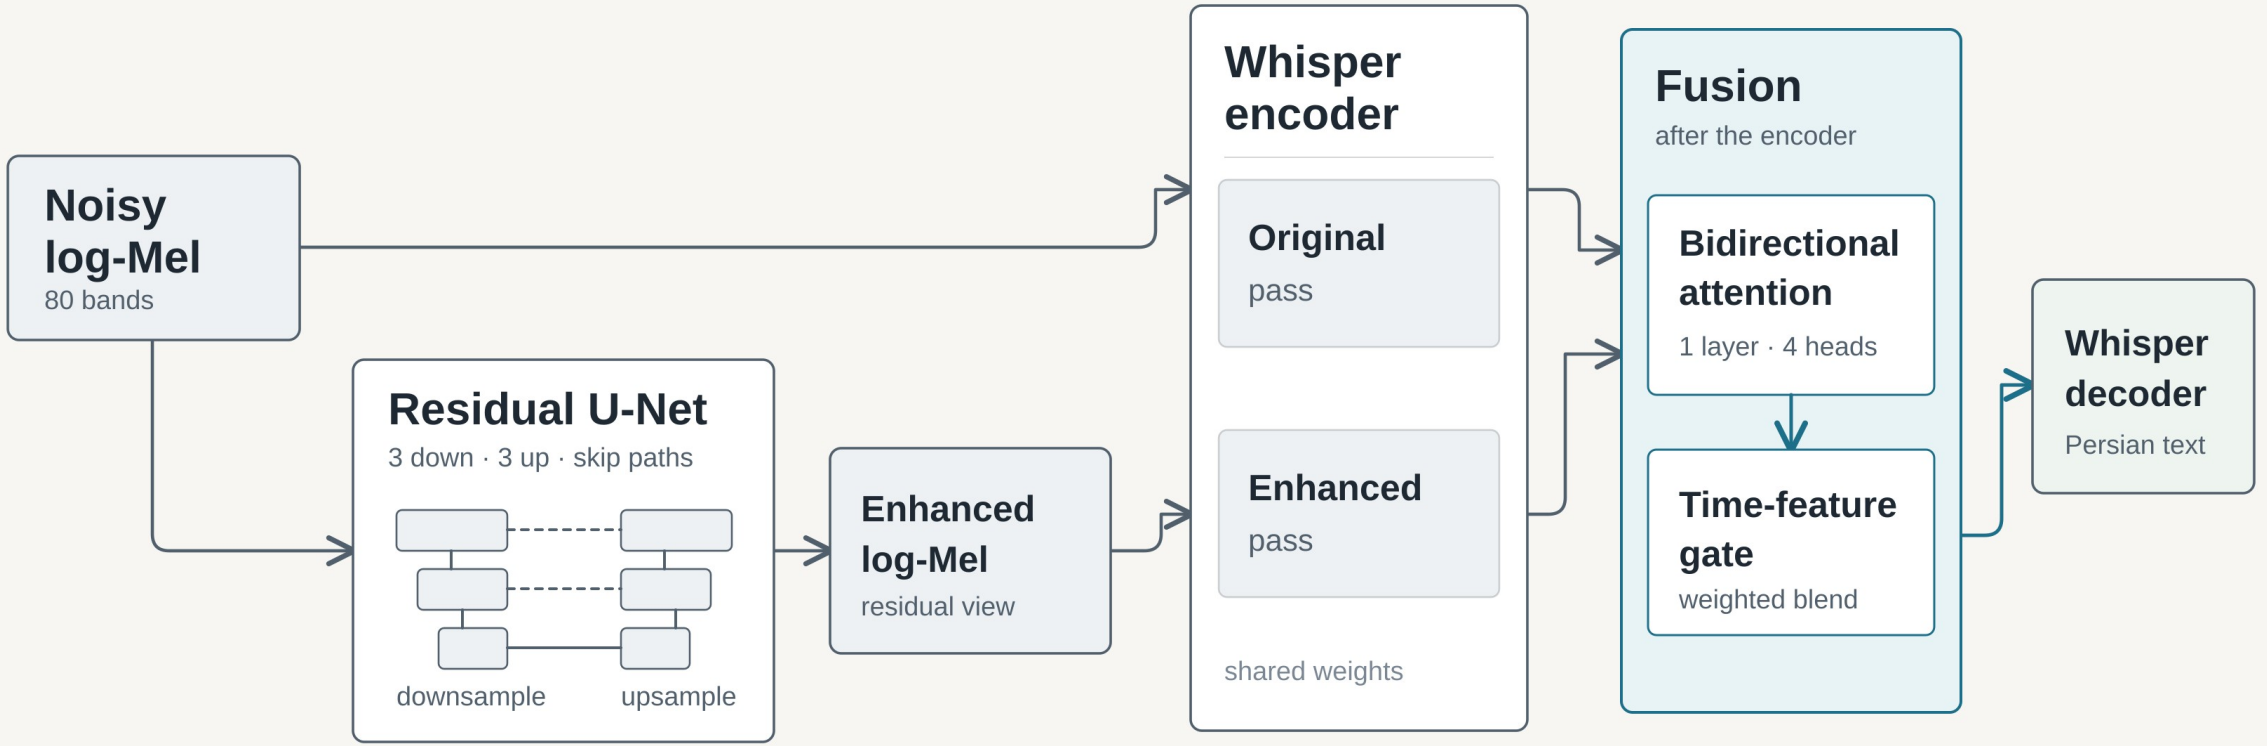
۲۷٫۶٪ کاهش نسبی

WER تجمیعی نیز از ۲۳٫۲۷٪ به ۱۷٫۸۳٪ کاهش یافت. مقدار کمتر بهتر است

اثر جداگانه کدک و اختلال شبکه در آزمایش حذفی سنجیده نشده است

معماری بهسازی و همجوشی دوجریانه

حفظ نمای اصلی در کنار نمای بهسازی‌شده



شروع از ویسپر کوچک چندشرایطی است. بهساز در حوزه لاگ‌مل کار می‌کند و موج صوتی بازسازی نمی‌کند

آموزش سه‌مرحله‌ای همجوشی



L_{enh}: log-Mel reconstruction · L_{feat}: encoder-feature matching · L_{ASR}: transcription loss

مرحله سوم: آموزش همه اجزا، شامل ویسپر

هر مرحله یک دوره کامل

نرخ نهایی: ماژول‌های جدید 1e-4
ویسپر 5e-6

داده مرحله نهایی

نمونه‌های تخریب‌شده و بلند
زیرمجموعه تصادفی ۲۵٪ از گفتار پاک

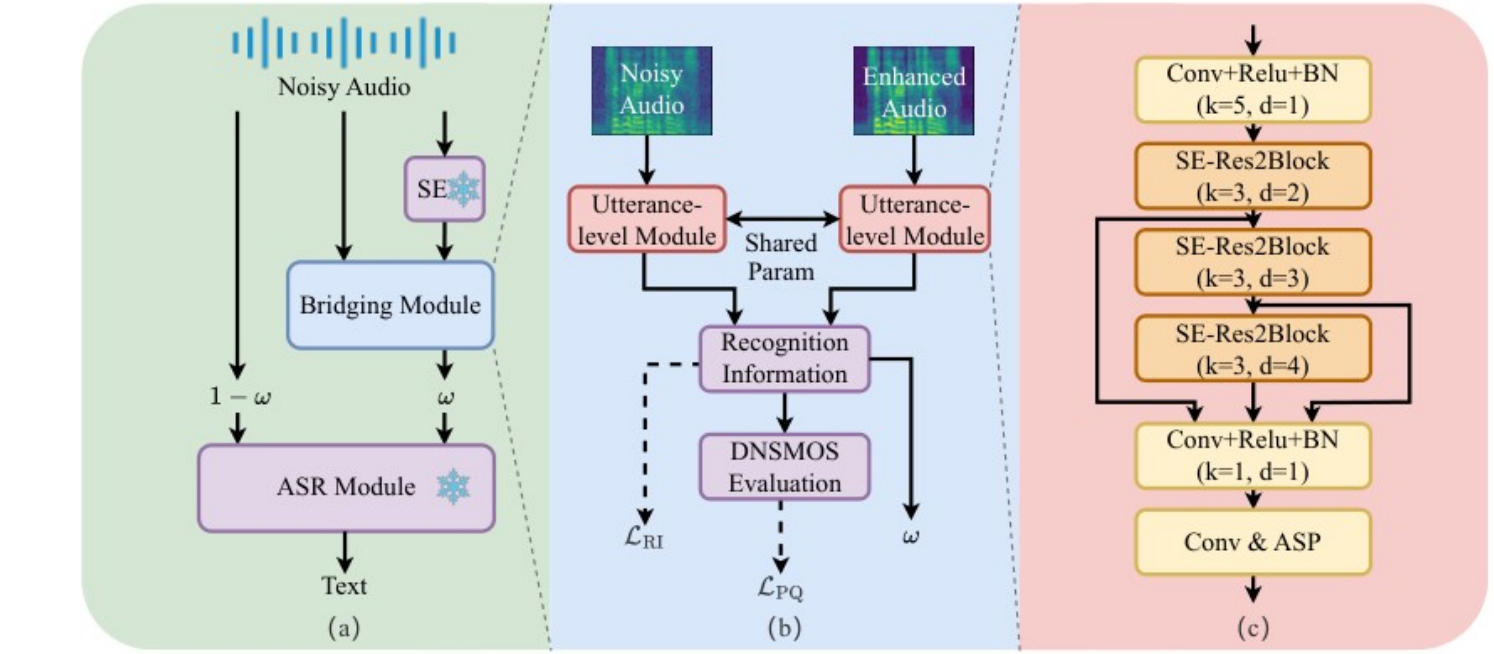
این آزمایش هم معماری و هم برنامه آموزش بازشناس را تغییر می‌دهد

پل تطبیقی پیش از بازشناسی

پیاده‌سازی این پایان‌نامه

بهساز FRCRN ثابت
بازشناس ویسپر ثابت
آموزش فقط ماژول پل

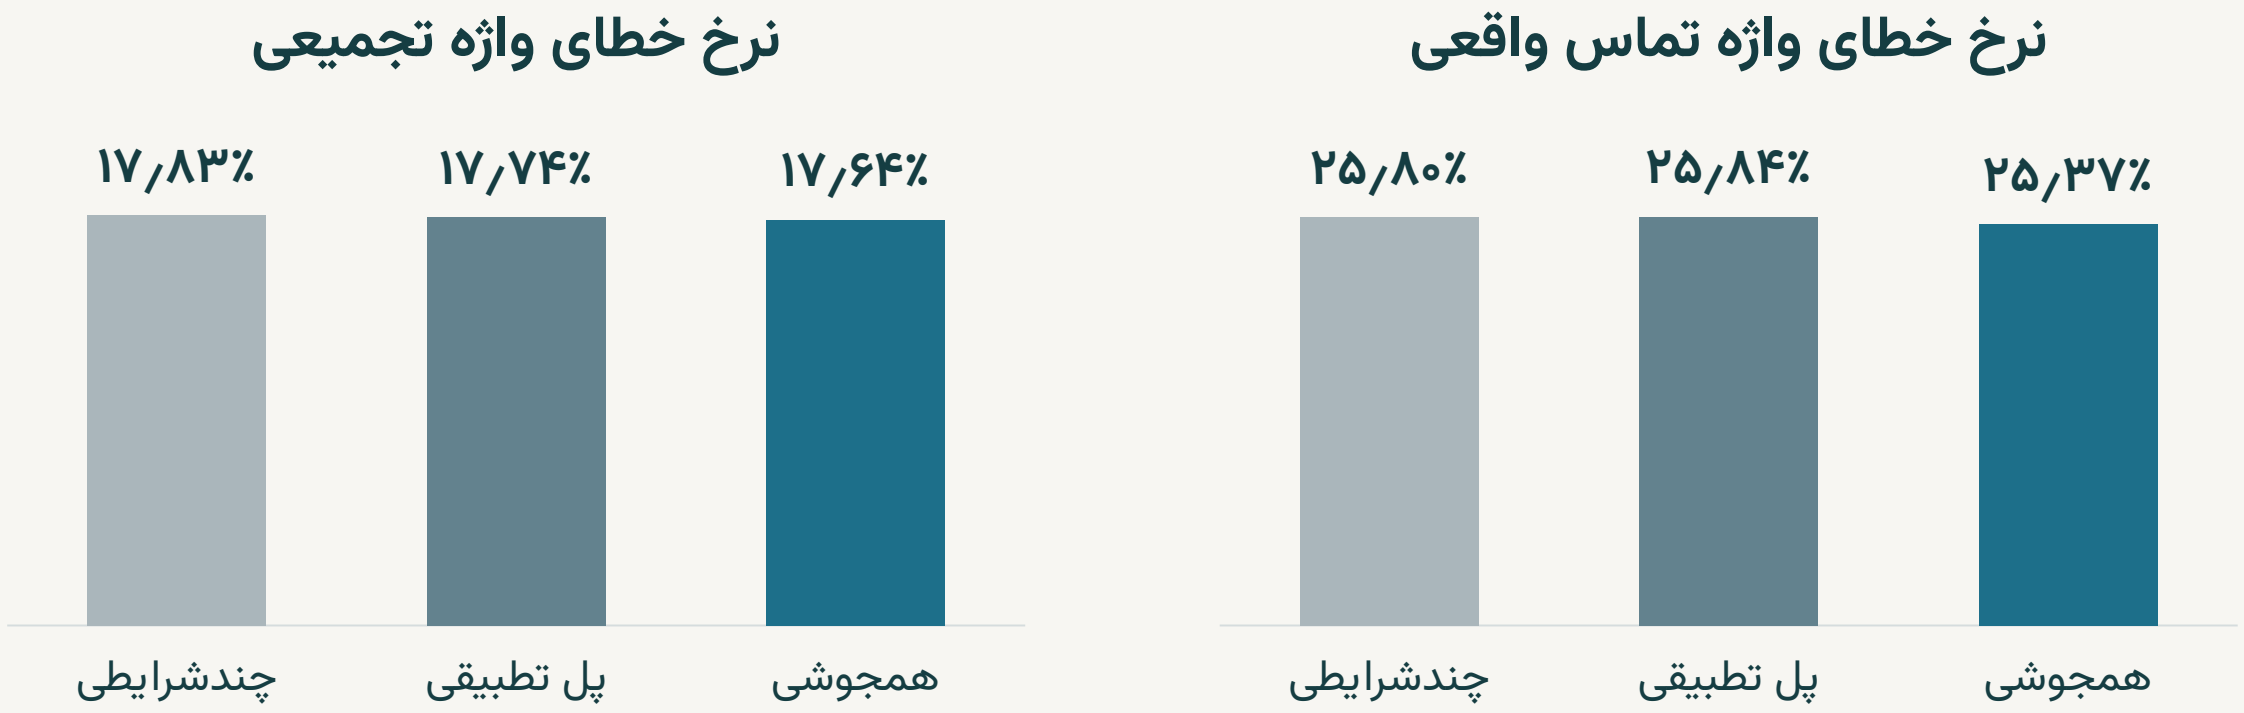
یک ضریب ترکیب
برای هر گفتار



Cui et al., ICASSP 2025, Fig. 1 (CC BY 4.0)

اجرای مستقل فارسی است. تفاوت بهساز و برنامه آموزش، انتساب اثر به محل ادغام را محدود می‌کند

سود افزوده همجوشی و پل تطبیقی

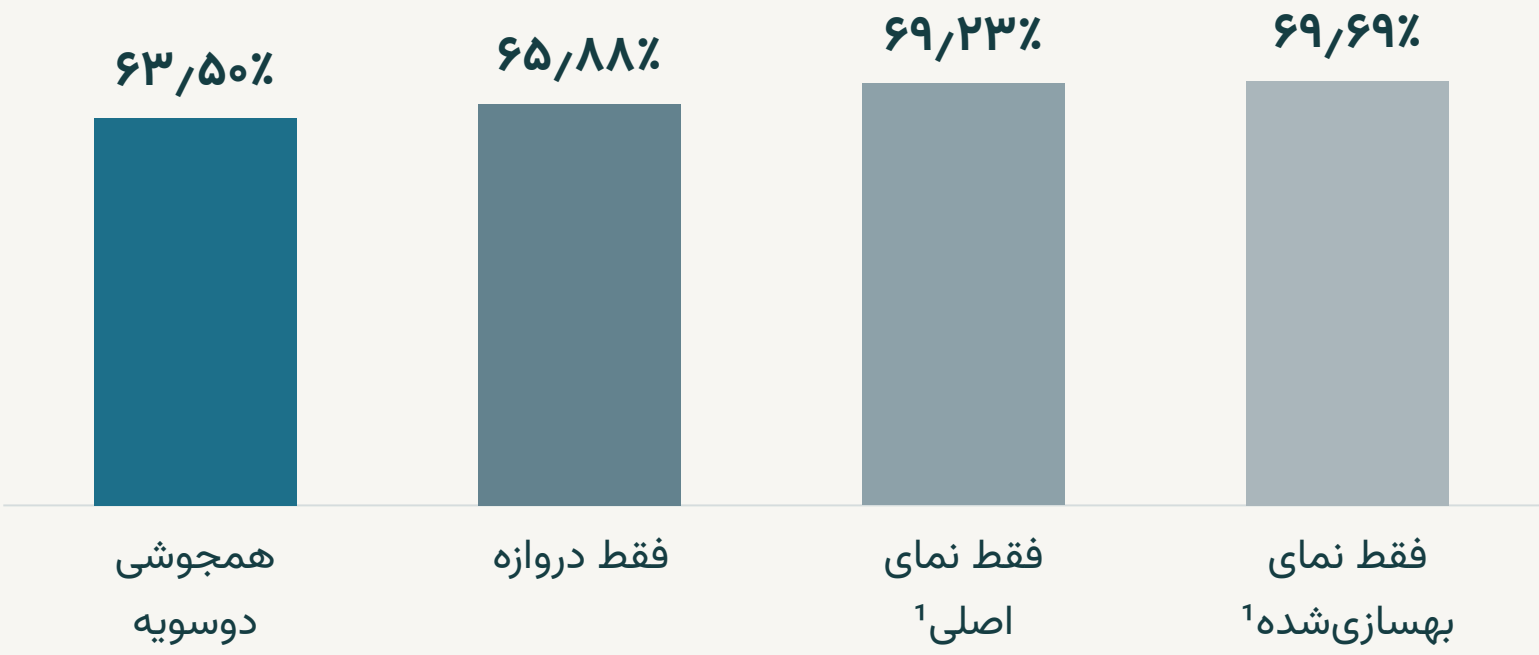


کاهش WER با همجوشی: ۰٫۱۹ واحد درصد تجمیعی و ۰٫۴۳ واحد درصد در تماس واقعی

CER تجمیعی به همین ترتیب: ۷٫۹۳٪، ۸٫۰۰٪ و ۷٫۸۵٪. اختلاف‌ها فاصله اطمینان ندارند

آزمایش حذفیِ دو نما و توجه متقاطع

نرخ خطای واژه در AGFarsdat



آزمایش مستقل ویسپر بسیار کوچک

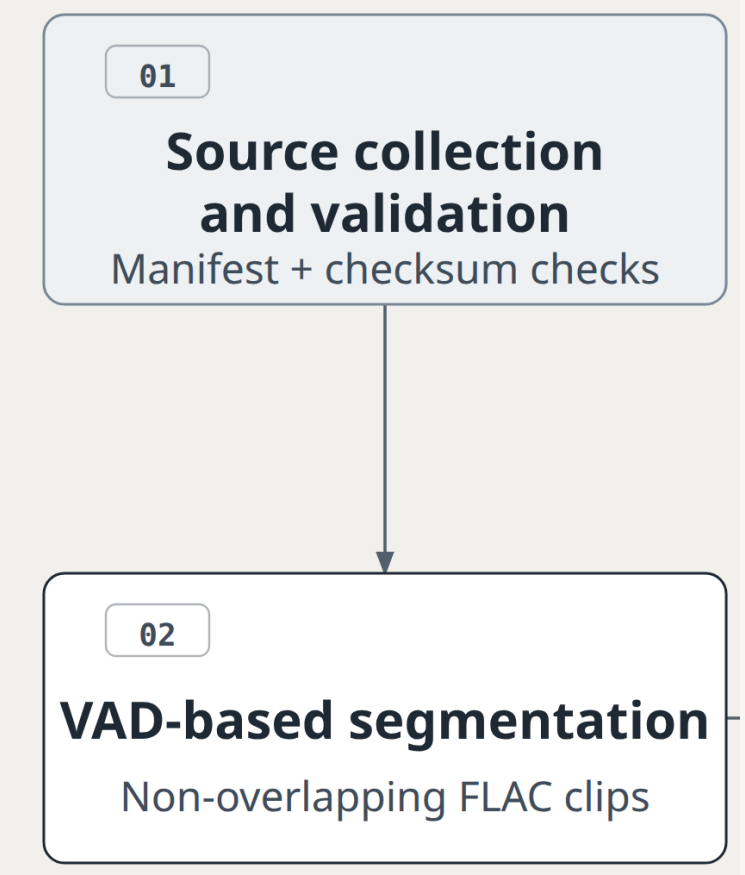
آموزش فقط با کامن‌وویس

WER کامن‌وویس به ترتیب نمودار

۵۷٫۸۲، ۶۲٫۳۵، ۶۴٫۱۰، ۶۳٫۸۱ درصد

[1] حذف نما در زمان استنتاج از مدل همجوشی آموزش‌دیده، نه آموزش مستقل یک مدل تک‌جریانه بودجه آموزش و تعداد پارامترهای نابرابر، تعیین سهم مستقل مؤلفه‌ها را محدود می‌کند

گردآوری و قطعه‌بندی ایران‌صدا



۳,۷۷۷ کتاب صوتی

حدود ۶,۳۰۰ ساعت صوت خام دریافت‌شده

۲۵۰ ساعت منتخب

طول هدف قطعه‌ها ۲۰ ثانیه است
بازه ترجیحی ۱۵ تا ۲۵، سقف سخت ۲۸ ثانیه

مجموعه گردآوری‌شده از زیرمجموعه انتخاب‌شده برای آموزش بزرگ‌تر است

رونویسی معلم، پالایش و آموزش

۱. رونویسی معلم

03

Whisper-Medium ASR

Raw pseudo-labels per clip

۲. نرمال‌سازی فارسی

04

Deterministic Persian normalization

Persian text conventions

۳. اصلاح با Qwen

05

LLM refinement

Qwen-based text correction

۴. پالایش کیفیت

06

Quality filtering

Reject invalid audio, labels, and Qwen edits

افزودن داده پذیرفته‌شده به ترکیب کامل گفتار معمولی، بلند و تخریب‌شده

معماری ویسپر کوچک، تنظیمات اصلی و تعداد گام‌های آموزش ثابت‌اند

داده پذیرفته‌شده و ملاحظات برچسب

۳۹,۴۵۴

قطعه پذیرفته‌شده

۲۱۸٫۵۶۴ ساعت

۴۴,۸۲۰ بررسی‌شده، ۵,۳۶۶ ردشده
۱۳۶ فایل منبع، تفکیک در سطح کتاب

ترجمه بخشی از دستور پالایش

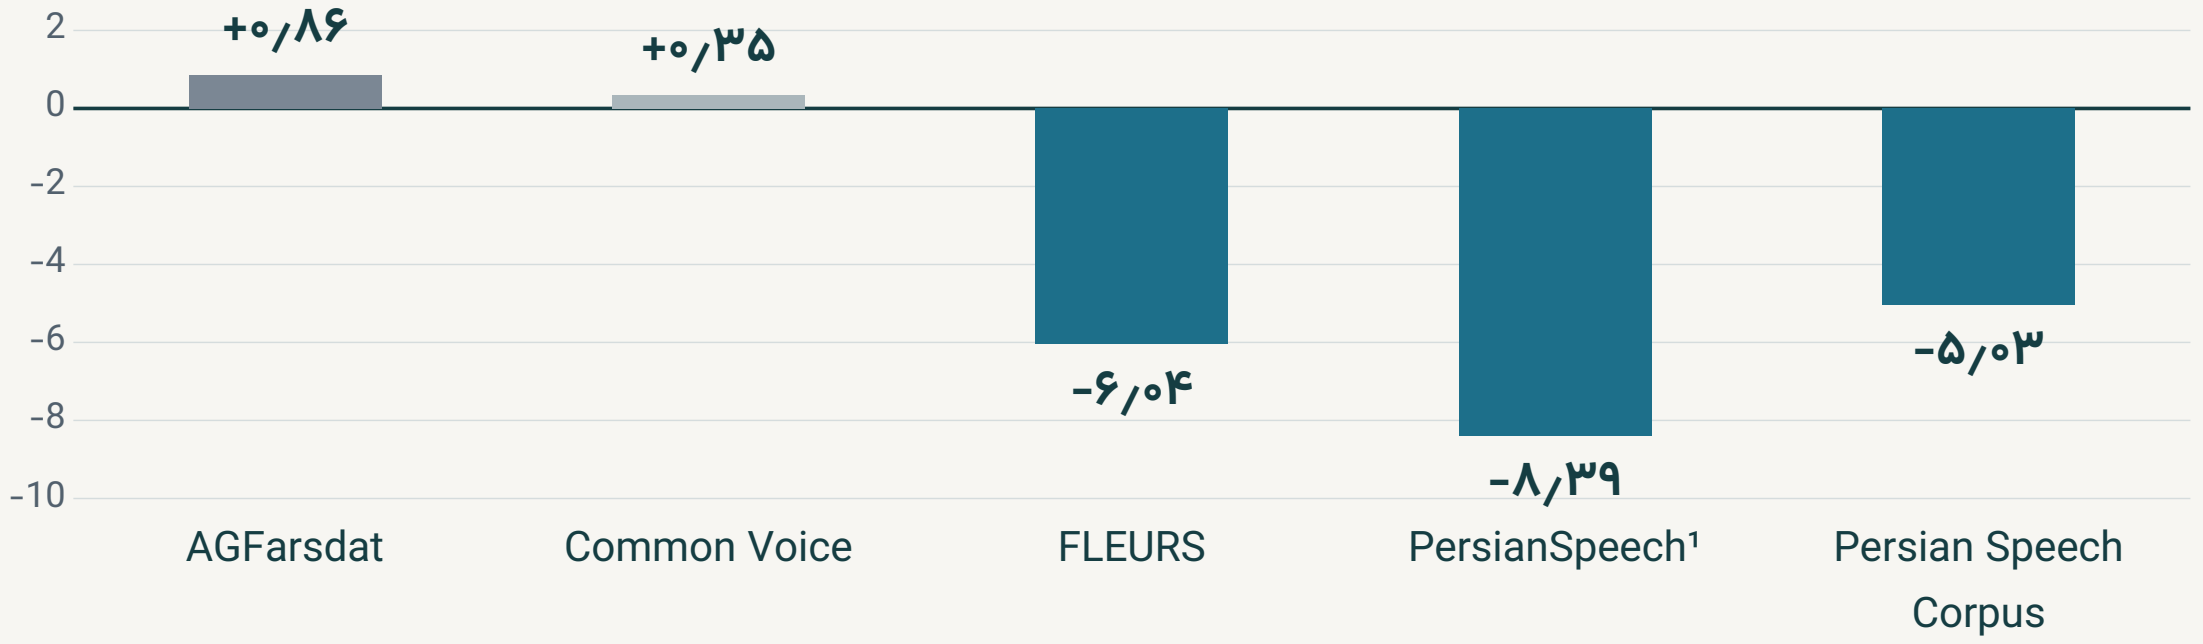
«همه نشانه‌های عددی را دقیقاً با همان رقم‌ها، علامت‌ها، جداکننده‌ها و قالب حفظ کن.»

Qwen فقط متن و بافت را دریافت می‌کند
رد موارد نامطمئن یا تغییرات بیش از حد
حفظ متن خام در کنار نسخه اصلاح‌شده

ممیزی انسانی کمّی برای دقت رونویسی انجام نشده است. ۴۰ شکست عملیاتی جداگانه ثبت شده‌اند

اثر ایران‌صدا به دامنه گفتار وابسته است

تغییر WER نسبت به مدل چندشرایطی، بر حسب واحد درصد



مقدار منفی یعنی بهبود. تغییر = با ایران‌صدا منهای خط مبنای چندشرایطی

تجمیعی: WER از ۱۷٫۸۳٪ به ۱۷٫۲۲٪ و CER از ۷٫۹۳٪ به ۷٫۷۰٪ رسید
¹ فقط ۲۴ نمونه. اثر سبک، کانال، کیفیت برچسب و نسبت نمونه‌برداری از هم جدا نشده است

نتیجه آزمایش‌های اصلی ویسپر کوچک

سامانه ویسپر کوچک	WER تجمیعی	WER تماس واقعی
معمولی	۲۳٫۲۷٪	۳۵٫۶۳٪
چندشرایطی	۱۷٫۸۳٪	۲۵٫۸۰٪
همجوشی پیشنهادی	۱۷٫۶۴٪	**۲۵٫۳۷٪**
چندشرایطی و ایران‌صدا	**۱۷٫۲۲٪**	۲۶٫۶۶٪

کمترین خطای تجمیعی: ایران‌صدا

کمترین خطای تماس واقعی: همجوشی

ویسپر متوسط: ۱۴٫۳۶٪ تجمیعی و ۲۱٫۹۹٪ تماس واقعی، با ظرفیت و آموزش متفاوت

محدودیت‌ها و آزمایش‌های بعدی

۱	اعتمادپذیری نتایج	اجرای چندبذری و نمونه‌های مشترک دقیق برآورد فاصله اطمینان برای اختلاف‌های کوچک
۲	سهم و هزینه همجوشی	کنترل با بودجه آموزش برابر و آزمایش حذفی در Small اندازه‌گیری زمان اجرا و حافظه
۳	کیفیت و تناسب داده	ممیزی انسانی متن معلم و اصلاح‌های مدل زبانی آزمایش نسبت داده و گفتار نزدیک به تماس

پوشش محدود شبیه‌ساز و خصوصی‌بودن آزمون تماس واقعی نیز دامنه شواهد را محدود می‌کنند

جمع‌بندی

بیشترین بهبود با آموزش متناسب با کانال

۳۵٫۶۳٪ به **۲۵٫۸۰٪**

نرخ خطای واژه در تماس‌های واقعی مستقل

همجوشی

۲۵٫۳۷٪ خطای تماس واقعی
بهبود عددی کوچک

داده کتاب صوتی

۱۷٫۲۲٪ خطای تجمیعی
سود وابسته به دامنه

**سپاسگزارم
پرسش‌ها**